机器学习

天国　付

November 2026

摘要

整理机器学习入门常用的模型、损失函数、训练方法与评价指标。以线性回归、梯度下降和逻辑回归为主要例子，只保留关键公式、简单算例与必要的使用条件。

关键词：机器学习；线性回归；梯度下降；逻辑回归；模型评价

目录

1　引言 **3**

2　机器学习的基本概念 **3**

2.1　数据、任务与模型 3

2.2　损失函数 3

2.3　训练好不等于预测好 3

3　线性回归与最小二乘法 **4**

3.1　核心思路 4

3.2　怎样直接求出直线 4

3.3　一个小例子 4

3.4　需要注意什么 4

4　梯度下降法 **4**

4.1　为什么需要它 4

4.2　在线性回归中怎样使用 5

4.3　学习率不能随意选 5

5　逻辑回归：预测二分类概率 **5**

5.1　从数值变为概率 5

5.2　用什么衡量预测误差 6

5.3　怎样调整参数 6

6　模型评价与过拟合 **6**

6.1　训练误差、测试误差 6

6.2 怎样划分数据 6
6.3 偏差与方差：理解模型为什么出错 7
6.4 分类任务看哪些指标 7

7 简短算例与代码 **7**

8 后续学习方向 **7**

A 常用符号 **8**

B 修订记录 **8**

参考文献 **9**

1 引言

这份笔记只整理机器学习入门阶段最常用的概念、公式与方法。重点是三个问题：**模型怎样预测**、**参数怎样求**、**效果怎样评价**。

正文依次介绍基本概念、线性回归、梯度下降、逻辑回归和模型评价。每节保留核心公式及必要条件，省略重复推导和暂时用不到的定理。数值例子与 Python 脚本用于辅助理解。

主要参考周志华《机器学习》、李航《统计学习方法》和 *An Introduction to Statistical Learning*[1-3]。

2 机器学习的基本概念

2.1 数据、任务与模型

训练数据由若干组 (x_i, y_i) 组成：x_i 是输入，y_i 是对应结果，m 是样本数。

- **回归：**预测连续数值，例如房价。
- **分类：**预测类别，例如邮件是否为垃圾邮件。
- **监督学习：**训练数据同时包含输入和答案；无监督学习通常没有对应标签。

最简单的预测模型是直线

$$\hat{y} = wx + b, \tag{2.1}$$

其中 w 是斜率，b 是截距。训练就是利用样本确定合适的参数。

2.2 损失函数

预测值 $\hat{y}_i$ 与真实值 y_i 的差叫作误差。回归中常用**均方误差**（MSE）：

$$\boxed{\mathrm{MSE} = \frac{1}{m}\sum_{i=1}^{m}(y_i - \hat{y}_i)^2.} \tag{2.2}$$

模型训练通常就是让损失尽可能小。例如，线性回归要选择使 MSE 较小的 w, b。平方误差计算方便，但对异常值较敏感。

2.3 训练好不等于预测好

训练误差衡量模型对已有样本的拟合；**测试误差**衡量它对未参与训练的数据的预测表现。训练误差很小，也可能发生过拟合。评价模型时必须关注新数据上的表现[1]第 1 章。

3 线性回归与最小二乘法

3.1 核心思路

对于一元线性回归，预测式为 $\hat{y}_i = wx_i + b$。最小二乘法选择让误差平方和最小的 w, b：

$$\boxed{J(w,b) = \frac{1}{2m}\sum_{i=1}^{m}(wx_i + b - y_i)^2.} \tag{3.1}$$

系数 $1/2$ 方便求导，不影响最优参数；实际报告的 MSE 则不包含这个 $1/2$。

3.2 怎样直接求出直线

记 $\bar{x}$ 为所有 x_i 的平均值，$\bar{y}$ 为所有 y_i 的平均值。对 w, b 求偏导并令其为零，得到

$$\boxed{\hat{w} = \frac{\sum_{i=1}^{m}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{m}(x_i - \bar{x})^2}, \qquad \hat{b} = \bar{y} - \hat{w}\bar{x}.} \tag{3.2}$$

使用条件：至少有两个不同的 x_i，否则分母为零，无法唯一确定斜率。这个公式说明拟合直线一定经过 $(\bar{x}, \bar{y})$[3]第 3 章。

3.3 一个小例子

给定 $(1,2), (2,3), (3,5)$，有 $\bar{x} = 2$, $\bar{y} = 10/3$。代入公式得到

$$\hat{w} = \frac{3}{2}, \qquad \hat{b} = \frac{1}{3},$$

所以拟合直线是 $\hat{y} = \frac{3}{2}x + \frac{1}{3}$。对应的 MSE 为 $1/18$。

3.4 需要注意什么

最小二乘法求的是**训练数据上的最佳拟合直线**，不保证因果关系，也不保证对新数据预测得好。它不要求误差一定服从正态分布；正态假设主要用于进一步进行统计推断或似然解释。

多个特征也可以做线性回归，但会用到矩阵计算。入门阶段先掌握上述一元公式即可。

4 梯度下降法

4.1 为什么需要它

最小二乘法有时能直接求解，但许多模型没有方便的计算公式。梯度下降采用**反复小步调整参数**的方法：沿着损失函数下降的方向移动，让误差逐渐减小[4]第 5 章。

对只有一个参数 w 的损失函数 $J(w)$，更新公式为

$$\boxed{w_{\text{新}} = w_{\text{旧}} - \eta J'(w_{\text{旧}}).} \tag{4.1}$$

这里 $\eta > 0$ 称为**学习率**。导数决定移动方向，学习率决定移动幅度。

4.2 在线性回归中怎样使用

对上一节的目标函数 $J(w,b)$，分别求导：

$$\frac{\partial J}{\partial w}=\frac{1}{m}\sum_{i=1}^{m}(wx_i+b-y_i)x_i,\qquad \frac{\partial J}{\partial b}=\frac{1}{m}\sum_{i=1}^{m}(wx_i+b-y_i). \tag{4.2}$$

然后同时按“原参数减去学习率乘导数”更新 w 和 b。

例如，取样本 $(1,2),(2,4)$，初值 $w=b=0$、学习率 $\eta=0.1$。此时两个偏导数分别是 -5 和 -3，更新一次后得到 $w=0.5,\ b=0.3$。这只是第一步，还要继续迭代。

4.3 学习率不能随意选

以 $J(w)=(w-2)^2$ 为例，最小值出现在 $w=2$。使用固定学习率时：

- $\eta=0.5$：一次就能到达最小点；
- $0<\eta<1$：从任意初值出发都能收敛；
- $\eta=1$：一般会来回振荡；$\eta>1$：一般会越走越远。

注意：这些范围只适用于本例，不是所有模型通用的规则。

梯度下降也不是万能的：如果损失函数不是凸函数，导数等于零的点未必是全局最小点。实际训练通常需要结合损失变化、验证集表现来判断是否继续迭代。

5 逻辑回归：预测二分类概率

5.1 从数值变为概率

二分类的答案通常用 0 和 1 表示。逻辑回归先计算 $z=wx+b$，再用 Sigmoid 函数将其变为概率：

$$\boxed{p=\frac{1}{1+\mathrm{e}^{-z}},\qquad z=wx+b.} \tag{5.1}$$

p 表示预测为正类（$y=1$）的概率。$z=0$ 时 $p=0.5$；z 越大，p 越接近 1。常见做法是以 0.5 为分类阈值，但实际应用可以调整。

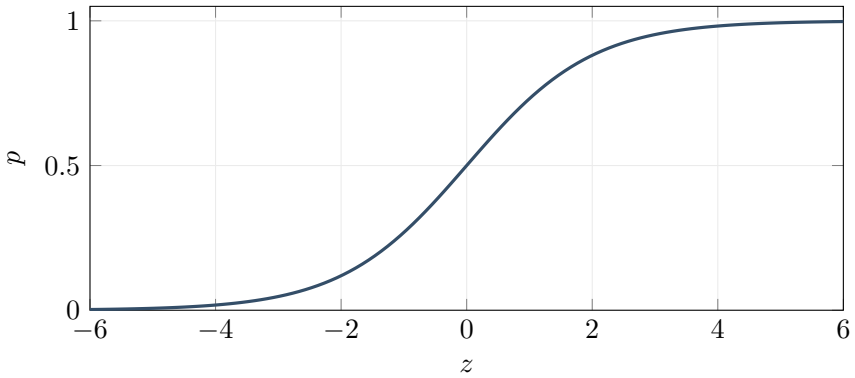


图 1: Sigmoid 函数：输出始终在 0 与 1 之间。

5.2 用什么衡量预测误差

逻辑回归通常使用**交叉熵损失**：

$$\boxed{J = -\frac{1}{m}\sum_{i=1}^{m}\left[y_i \ln p_i + (1-y_i)\ln(1-p_i)\right].} \tag{5.2}$$

当真实类别是 1 时，模型给出的 p_i 越大越好；真实类别是 0 时则相反。这个损失来自伯努利概率模型的负对数似然[2]第 6 章。

5.3 怎样调整参数

对上述模型求导后，可得到

$$\frac{\partial J}{\partial w} = \frac{1}{m}\sum_{i=1}^{m}(p_i - y_i)x_i, \qquad \frac{\partial J}{\partial b} = \frac{1}{m}\sum_{i=1}^{m}(p_i - y_i). \tag{5.3}$$

和线性回归一样，可以用梯度下降更新 w, b；**区别是这里预测的是概率，使用的是交叉熵，而不是平方误差**。

例如只有样本 $(x, y) = (1, 1)$，初始 $w = b = 0$，则 $p = 0.5$。学习率取 0.1，更新一次后 $w = b = 0.05$。

逻辑回归并不要求数据本身呈直线分布，但它用线性表达式 $wx + b$ 来决定分类概率。

6 模型评价与过拟合

6.1 训练误差、测试误差

欠拟合：模型太简单，连训练数据的主要规律也没有学好。**过拟合**：模型在训练集上表现很好，但遇到新数据效果明显变差。

例如，多项式次数越高，通常越容易贴合训练点，但测试误差不一定更低。仓库中的 `code/polynomial_compariso` 可以用来观察这种现象[1]第 2 章。

6.2 怎样划分数据

- **训练集：**用来学习模型参数。
- **验证集：**用来选择模型和超参数。
- **测试集：**留到最后，检查最终预测效果。

样本不多时，可使用 K **折交叉验证**：把训练部分分为 K 份，每轮用其中一份验证、其余训练，最后平均验证误差（各折样本量相同时）：

$$\boxed{\mathrm{CV} = \frac{E_1 + \cdots + E_K}{K}.} \tag{6.1}$$

常用 $K = 5$ 或 10，但要根据数据特点选择。标准化、缺失值填补等处理应只在每轮训练折上拟合，以免发生**数据泄漏**[3]第 5 章。

6.3 偏差与方差：理解模型为什么出错

对平方误差，在常见的零均值、独立噪声等假设下，有

$$\boxed{\text{平均预测误差} = \text{偏差}^2 + \text{方差} + \text{噪声方差}.} \tag{6.2}$$

偏差大，表示模型的平均预测离真实规律较远；方差大，表示模型对训练数据的变化过于敏感。模型越复杂不一定越好，要在两者之间取得平衡[3]第 2 章。

6.4 分类任务看哪些指标

设 TP 是预测正确的正类数，FP 是误报的正类数，FN 是漏报的正类数。常用指标为

$$\text{精确率} = \frac{TP}{TP+FP}, \qquad \text{召回率} = \frac{TP}{TP+FN}. \tag{6.3}$$

F_1 是精确率与召回率的调和平均数。类别不平衡时，不宜只看准确率；例如 100 个样本中只有 5 个正类，全部预测为负类虽然有 95% 的准确率，却一个正类也没找出来。

核心原则：不能反复用测试集调参；数据划分也应考虑时间顺序和同一对象的重复观测。

7 简短算例与代码

本仓库提供三个 Python 示例，帮助核对前面的公式，而不是用复杂的实验表格替代理解。

- `code/linear_regression_demo.py`：比较最小二乘法与梯度下降。对样本 $(1,2),(2,3),(3,5)$，解析解为 $w=1.5$，$b=1/3$，MSE 为 $1/18$。
- `code/logistic_gradient_check.py`：检查逻辑回归的求导结果是否与数值近似一致。
- `code/polynomial_comparison.py`：比较不同次数多项式的训练误差与测试误差。

运行前安装依赖：`python -m pip install -r requirements.txt`。三个脚本均可分别用 `python code/文件名.py` 运行。

看实验时主要关注**数据**、**参数**、**误差和结论**。更换样本或学习率后，结果可能变化，不能把一次实验视为普遍规律。

8 后续学习方向

现阶段先掌握模型、损失、参数更新和测试评价。后续可以按需要继续学习：

- **正则化：**用岭回归、Lasso 等方法限制模型过于复杂。
- **更多模型：**决策树、支持向量机及集成学习。
- **统计推断：**参数估计的不确定性、置信区间与假设检验。
- **优化方法：**随机梯度下降及其他更高效的训练算法。

新主题单独成节，不在入门笔记中提前堆放未讲解的定理。

A 常用符号

符号	含义
m	训练样本数
x_i, y_i	第 i 个输入、真实结果
$\hat{y}_i$	模型预测结果
w, b	斜率、截距（模型参数）
$\bar{x}$, $\bar{y}$	输入与结果的样本均值
J	训练时希望减小的损失
η	梯度下降的学习率
p_i	逻辑回归预测正类的概率
K	交叉验证的折数
TP, FP, FN	正确预测正类、误报、漏报的数量

各节只引入当前需要的符号；未使用的复杂记号不再单独罗列。

B 修订记录

日期	版本	修订内容
2026-11-11	v0.2	精简全文：删去重复定理、长证明及非必要的矩阵公式，改用直观表述，保留核心公式和算例。
2026-11	v0.1	建立可持续扩展的文稿；整理学习框架、最小二乘、梯度下降、逻辑回归、模型评价及基础数值实验。

后续增加模型或更改公式时，应在此记录改动原因；出现教材间的符号或结论差异时，优先保留各自成立的假设，再进行比较。

参考文献

[1] 周志华. 机器学习[M]. 清华大学出版社, 2016.

[2] 李航. 统计学习方法[M]. 2 版. 清华大学出版社, 2019.

[3] James G, Witten D, Hastie T, Tibshirani R, Taylor J. An Introduction to Statistical Learning: With Applications in Python[M/OL]. Springer, 2023. DOI: 10.1007/978-3-031-38747-0.

[4] 刘浩洋, 户将, 李勇锋, 文再文. 最优化计算方法（简化版）[M]. 2020.