机器学习

天国　付

November 2026

摘要

本文围绕统计学习中的模型构建、参数估计、数值优化与泛化评估，整理基础定义、主要公式及其推导条件。讨论以线性回归和二分类概率模型为主，同时记录梯度下降的数学性质、模型评估的常用方法与可复现的数值算例。文稿按照研究问题组织，而非课堂顺序；后续将逐步补充正则化、优化算法及相关实验。

关键词：统计学习；最小二乘；梯度下降；逻辑回归；泛化误差

目录

1　引言 **3**

2　从数据到优化问题 **3**

2.1　统计学习的对象 3
2.2　损失函数和经验风险 3
2.3　经验风险与总体风险 4
2.4　一个不依赖数值优化器的例子 4
2.5　保留的问题 4

3　线性回归与最小二乘估计 **5**

3.1　模型和目标函数 5
3.2　一元最小二乘的显式解 5
3.3　矩阵形式与正规方程 6
3.4　残差的正交性与几何解释 6
3.5　与正态噪声极大似然的联系 7
3.6　小结与边界 7

4　一阶优化方法：梯度下降与步长 **7**

4.1　迭代法的出发点 7
4.2　方向导数与负梯度 7
4.3　线性回归中的梯度 8
4.4　学习率与一个可完整分析的例子 8
4.5　一般光滑目标的下降估计 9

4.6 凸性、驻点与全局最优 10
4.7 后续扩展 10

5 二分类的概率建模与对数损失 10
5.1 从线性得分到条件概率 10
5.2 Sigmoid 的导数 10
5.3 伯努利似然与交叉熵 11
5.4 从链式法则推导梯度 11
5.5 Hessian、凸性与例外情形 12
5.6 一次相容的手工更新 12
5.7 模型解释与适用范围 12

6 模型评价、过拟合与泛化分析 12
6.1 评价对象：训练误差与总体风险 12
6.2 欠拟合、过拟合与模型复杂度 13
6.3 平方误差下的偏差—方差分解 13
6.4 留出法与交叉验证 14
6.5 二分类的常用评价指标 14
6.6 评价结果的统计解释 15

7 数值计算与实验记录 15
7.1 一元线性回归的解析核对 15
7.2 NumPy 实现与结果比较 16
7.3 逻辑回归的梯度一致性检查 16
7.4 实验记录规范 16

8 讨论与后续研究方向 17
8.1 从最小化训练风险到控制模型复杂度 17
8.2 从解析方法到一般数值优化 17
8.3 从点估计到统计推断 17
8.4 仍需回答的问题 17

A 主要符号及约定 17

B 修订记录 18

参考文献 19

1 引言

机器学习以样本数据为基础，借助模型及算法建立从输入到输出的映射。对于回归与分类问题，模型训练通常可以写成经验损失的最小化，但目标函数的性质、参数估计的统计含义与模型在新数据上的预测效果应分别考察。特别是，找到经验风险的最小点，并不直接意味着得到了泛化性能最好的模型。

本文采用统一记号，从几个可以完整推导的问题入手：先说明数据、模型族、损失函数与经验风险的关系；再讨论线性回归最小二乘估计的解析形式及几何解释；继而研究梯度下降的局部下降依据和步长条件；随后由伯努利分布导出逻辑回归的交叉熵损失；最后分析模型评估、偏差—方差分解与交叉验证。数值示例用于检验理论，不取代证明。

主要参阅周志华《机器学习》、李航《统计学习方法（第 2 版）》、James 等人的 *An Introduction to Statistical Learning: With Applications in Python* 以及《最优化计算方法（简化版）》[1-4]。凡属教材中的理论内容，尽量标注相关章节；自行整理的推导与实验记录并不冒充原书文字。

后续将沿用相同符号体系增补正则化、模型选择、决策树、支持向量机及进一步的优化理论，必要时修订既有表述。

2 从数据到优化问题

2.1 统计学习的对象

考虑训练数据

$$D = \{(x_i, y_i)\}_{i=1}^{m}, \qquad x_i \in \mathcal{X}, \quad y_i \in \mathcal{Y}. \tag{2.1}$$

其中 x_i 为输入、y_i 为目标变量，m 为样本数。若输入是 p 维数值向量，则 $x_i \in \mathbb{R}^p$。监督学习利用输入与目标之间的对应关系估计预测函数；无监督学习通常只有输入数据，其目标是发现数据的结构，例如聚类或低维表示[1]第 1 章。

对监督学习而言，回归任务的目标变量通常是连续数值；分类任务的目标变量是有限个类别。分类器可以输出类别，也可以先输出类别的条件概率，再根据决策规则得到最终类别。是否使用梯度下降并不决定任务类型；任务类型取决于待预测的变量和问题设定。

以简单线性模型为例，假设类为

$$\mathcal{F} = \{f_{w,b}(x) = wx + b : \ w, b \in \mathbb{R}\}. \tag{2.2}$$

模型族 $\mathcal{F}$ 规定允许采用怎样的函数形式；参数 w, b 选择其中一个具体模型；优化算法则确定怎样利用数据求得参数。三者在概念上应当分开。

2.2 损失函数和经验风险

预测结果未必与观测值相同，需要用损失函数 $L(y, \hat{y})$ 量化差异。常见的回归损失为平方损失

$$L(y, \hat{y}) = (y - \hat{y})^2. \tag{2.3}$$

在有限样本上取平均，得到经验风险

$$\widehat{R}_D(f) = \frac{1}{m} \sum_{i=1}^{m} L\big(y_i, f(x_i)\big). \tag{2.4}$$

因此，经验风险最小化（empirical risk minimization, ERM）可以写成

$$\hat{f} \in \arg\min_{f \in \mathcal{F}} \widehat{R}_D(f). \tag{2.5}$$

式 (2.5) 说明学习问题如何转化为优化问题，但没有规定一定使用哪种算法。对可以直接求解的模型，可使用解析方法；对难以得到闭式解的模型，常考虑数值迭代方法。

平方损失的优点在于非负、连续可微，且有利于构造最小二乘问题；不足之处是较大的残差会受到二次惩罚，因此估计结果可能对异常值较敏感。损失函数并非只有一种，后文讨论二分类时将使用由概率模型导出的对数损失。

2.3 经验风险与总体风险

若数据来自未知联合分布 $P_{X,Y}$，则可定义总体风险

$$R(f) = \mathbb{E}_{(X,Y)\sim P_{X,Y}}\big[L(Y, f(X))\big]. \tag{2.6}$$

经验风险用样本均值近似总体期望；两者通常并不相等。训练过程直接接触到的是样本，而预测最终面向未知观测，这种差别是泛化问题的起点[2]第 1 章。

命题 2.1 (固定预测函数时经验风险的无偏性)**.** *设 $Z_i = (X_i, Y_i)$ 独立同分布，且 $\mathbb{E}\,|L(Y, f(X))| < \infty$。若预测函数 f 在观测该训练样本之前已固定，则*

$$\mathbb{E}_D\big[\widehat{R}_D(f)\big] = R(f). \tag{2.7}$$

证明. 由期望的线性性及相同分布，

$$\mathbb{E}_D\left[\frac{1}{m}\sum_{i=1}^{m} L(Y_i, f(X_i))\right] = \frac{1}{m}\sum_{i=1}^{m}\mathbb{E}[L(Y_i, f(X_i))] = R(f).$$

此处不需要各损失项彼此独立才能使用期望线性性；独立同分布是给定的典型抽样假设。 □

注记 2.2. 命题 2.1 的关键是 f 在样本被观察前已固定。训练所得的 $\hat{f}_D$ 依赖于同一批数据，不能把它不加区别地代入上述证明；否则容易错误地认为训练误差天然就是泛化误差的无偏估计。

2.4 一个不依赖数值优化器的例子

对于 $D = \{(1,2), (2,4), (3,6)\}$，考虑过原点的线性模型 $f_w(x) = wx$。其均方误差为

$$\widehat{R}_D(w) = \frac{1}{3}\big[(w-2)^2 + (2w-4)^2 + (3w-6)^2\big] \tag{2.8}$$

$$= \frac{14}{3}(w-2)^2. \tag{2.9}$$

由完全平方的非负性可知 $\widehat{R}_D(w) \geq 0$，且等号仅在 $w = 2$ 时成立。因此 $w^* = 2$ 是唯一全局最小点，最优值为零。这个例子说明：建立优化问题和选择求解算法是两件事。这里直接观察平方项即可求解，无须调用梯度下降。

2.5 保留的问题

经验风险最小化何时能得到接近总体风险最小值的模型？这一问题依赖函数类的复杂度、抽样假设及评价方法，不能仅凭目标函数的最优值回答。相关讨论放在第 6 节，并在今后的学习中继续补充更严格的泛化界。

3 线性回归与最小二乘估计

3.1 模型和目标函数

对单个数值特征，采用含截距的线性预测函数

$$\hat{y}_i = w x_i + b. \tag{3.1}$$

记残差 $e_i = y_i - \hat{y}_i$，残差平方和（RSS）为

$$\mathrm{RSS}(w, b) = \sum_{i=1}^{m} (y_i - w x_i - b)^2. \tag{3.2}$$

最小二乘法选择使 RSS 最小的参数。推导时常用等价目标

$$J(w, b) = \frac{1}{2m} \sum_{i=1}^{m} (w x_i + b - y_i)^2. \tag{3.3}$$

其中系数 $1/(2m)$ 不改变最优解：$1/m$ 对应平均损失，$1/2$ 用于简化求导。另一方面，如果讨论指标 MSE，则必须仍然采用 $1/m$，不能将目标函数 J 和 MSE 视作完全相同的数值量[3]第 3 章。

3.2 一元最小二乘的显式解

令 $\bar{x} = m^{-1} \sum_i x_i$、$\bar{y} = m^{-1} \sum_i y_i$。分别求偏导，

$$\frac{\partial J}{\partial b} = \frac{1}{m} \sum_{i=1}^{m} (w x_i + b - y_i), \tag{3.4}$$

$$\frac{\partial J}{\partial w} = \frac{1}{m} \sum_{i=1}^{m} x_i (w x_i + b - y_i). \tag{3.5}$$

令 (3.4) 为零，得到

$$b = \bar{y} - w \bar{x}. \tag{3.6}$$

再将其代入 (3.5)，可得

$$\sum_{i=1}^{m} x_i \big[w(x_i - \bar{x}) - (y_i - \bar{y}) \big] = 0.$$

利用 $\sum_i (x_i - \bar{x}) = 0$ 与 $\sum_i (y_i - \bar{y}) = 0$，整理成

$$w \sum_{i=1}^{m} (x_i - \bar{x})^2 = \sum_{i=1}^{m} (x_i - \bar{x})(y_i - \bar{y}).$$

只要自变量并非全都相同，即 $\sum_i (x_i - \bar{x})^2 > 0$，便得到

$$\boxed{\hat{w} = \frac{\sum_{i=1}^{m} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{m} (x_i - \bar{x})^2}, \qquad \hat{b} = \bar{y} - \hat{w} \bar{x}.} \tag{3.7}$$

因此，含截距的最小二乘拟合直线经过点 $(\bar{x}, \bar{y})$。这是一条由正规方程得到的代数结论，并不要求真实条件期望严格线性。

从统计学角度看，斜率还可写成样本协方差与样本方差之比：

$$\hat{w} = \frac{\widehat{\mathrm{Cov}}(X, Y)}{\widehat{\mathrm{Var}}(X)},$$

前提是协方差和方差采用相同的归一化分母，并且样本方差非零。

3.3 矩阵形式与正规方程

对含 p 个待估参数的线性模型，设设计矩阵 $X \in \mathbb{R}^{m\times p}$、参数 $\beta \in \mathbb{R}^p$、目标向量 $y \in \mathbb{R}^m$。若需要截距，可将全 1 列作为 X 的一列。目标函数为

$$J(\beta) = \frac{1}{2m}\,\|X\beta - y\|_2^2 . \tag{3.8}$$

展开为

$$J(\beta) = \frac{1}{2m}\big(\beta^{\mathsf T}X^{\mathsf T}X\beta - 2y^{\mathsf T}X\beta + y^{\mathsf T}y\big).$$

对 β 求梯度与 Hessian，

$$\nabla J(\beta) = \frac{1}{m}X^{\mathsf T}(X\beta - y), \qquad \nabla^2 J(\beta) = \frac{1}{m}X^{\mathsf T}X. \tag{3.9}$$

因此驻点满足正规方程

$$X^{\mathsf T}X\hat\beta = X^{\mathsf T}y. \tag{3.10}$$

若 X 满列秩，$X^{\mathsf T}X$ 正定且可逆，从而

$$\boxed{\hat\beta = (X^{\mathsf T}X)^{-1}X^{\mathsf T}y.} \tag{3.11}$$

命题 3.1 (最小二乘目标的凸性与解的唯一性)**.** *对任意实矩阵 X，式 (3.8) 定义的目标函数是凸函数；若 X 满列秩，则它严格凸，且最小二乘解唯一。*

证明. 对任意 $v \in \mathbb{R}^p$，

$$v^{\mathsf T}\nabla^2 J(\beta)v = \frac{1}{m}v^{\mathsf T}X^{\mathsf T}Xv = \frac{1}{m}\,\|Xv\|_2^2 \ge 0.$$

所以 Hessian 半正定，目标函数凸。当 X 满列秩时，$v \neq 0$ 蕴含 $Xv \neq 0$，从而上式严格大于零，Hessian 正定，目标函数严格凸。此时驻点存在且唯一，故 (3.11) 是唯一全局最小点。 □

注记 3.2. 若 X 不满列秩，$X^{\mathsf T}X$ 不可逆，不能机械套用式 (3.11)。最小二乘解仍存在，但参数可能不唯一。此时可使用 Moore–Penrose 伪逆获得最小范数解：$\hat\beta = X^{+}y$。实际数值计算中，QR 分解或奇异值分解通常比显式计算 $(X^{\mathsf T}X)^{-1}$ 更稳健。

3.4 残差的正交性与几何解释

由正规方程 (3.10) 可知

$$X^{\mathsf T}(y - X\hat\beta) = 0. \tag{3.12}$$

换言之，残差向量 $r = y - X\hat\beta$ 与 X 的每一列正交。拟合值 $\hat y = X\hat\beta$ 是观测向量 y 在 X 列空间上的正交投影。即便参数不唯一，投影 $\hat y$ 仍然唯一。

若设计矩阵包含一列全 1 向量，则残差之和为零：

$$\sum_{i=1}^{m}(y_i - \hat y_i) = 0.$$

这一性质来自最小二乘的一阶最优性，而不是一般预测算法都满足的规律。

3.5 与正态噪声极大似然的联系

进一步假设

$$Y_i = x_i^{\mathsf{T}}\beta + \varepsilon_i, \qquad \varepsilon_i \overset{\text{i.i.d.}}{\sim} N(0, \sigma^2), \tag{3.13}$$

其中这里 x_i 表示设计矩阵第 i 行对应的列向量，$\sigma^2 > 0$。对固定的 σ^2，负对数似然（略去与 β 无关的常数）为

$$-\ell(\beta) = \frac{1}{2\sigma^2}\sum_{i=1}^{m}(y_i - x_i^{\mathsf{T}}\beta)^2 + \text{const.}$$

因此在上述正态、独立且同方差的噪声模型下，β 的极大似然估计与最小二乘估计一致。**然而，求最小二乘解本身并不需要假设误差正态**。正态性是将其解释为上述似然模型估计方法时加入的条件。

3.6 小结与边界

最小二乘法回答的是给定线性函数族后，怎样选取使残差平方和最小的参数。它不自动保证回归系数具有因果解释，不保证线性模型正确，也不保证测试误差足够小。后续还需分别研究建模假设、统计推断、数值稳定性与泛化能力。

4 一阶优化方法：梯度下降与步长

4.1 迭代法的出发点

最小二乘问题在适当的秩条件下可以写出显式解，但许多优化目标没有便于直接计算的闭式解。对可微函数 $J : \mathbb{R}^p \to \mathbb{R}$，考虑

$$\min_{\theta \in \mathbb{R}^p} J(\theta).$$

迭代方法从初值 θ_0 出发，构造 $\theta_1, \theta_2, \ldots$，希望目标函数逐步下降，最终得到近似最优解。需要区分两个概念：下降方向决定局部朝哪里移动，步长决定一次移动多远。即便方向正确，过大的步长仍可能使函数值上升。

4.2 方向导数与负梯度

若 J 在 θ 处可微，沿单位方向 d 的方向导数为

$$D_d J(\theta) = \nabla J(\theta)^{\mathsf{T}} d, \qquad \|d\|_2 = 1. \tag{4.1}$$

依据 Cauchy–Schwarz 不等式，

$$\nabla J(\theta)^{\mathsf{T}} d \geq -\|\nabla J(\theta)\|_2 .$$

当 $\nabla J(\theta) \neq 0$ 时，取

$$d_* = -\frac{\nabla J(\theta)}{\|\nabla J(\theta)\|_2} \tag{4.2}$$

达到上述下界。因此负梯度是欧氏范数下局部一阶变化率最小的单位方向。这里的“最速”是局部概念，不意味着一步更新就达到全局最优点，也不保证任意步长均能下降[4]第 5 章。

梯度下降法把方向与步长结合起来，得到

$$\boxed{\theta_{k+1} = \theta_k - \eta_k \nabla J(\theta_k), \qquad \eta_k > 0.} \tag{4.3}$$

对于含斜率和截距的模型，应先在 (w_k, b_k) 处计算梯度，再同步更新这两个参数。

如果在一次迭代中先更新 w，再用新的 w 更新 b，得到的便是另一种顺序更新方法。

4.3 线性回归中的梯度

对含截距的简单线性回归，

$$J(w,b)=\frac{1}{2m}\sum_{i=1}^{m}(wx_i+b-y_i)^2.$$

由链式法则，

$$\frac{\partial J}{\partial w}=\frac{1}{m}\sum_{i=1}^{m}(wx_i+b-y_i)x_i,\quad \frac{\partial J}{\partial b}=\frac{1}{m}\sum_{i=1}^{m}(wx_i+b-y_i). \tag{4.4}$$

对应的同步更新为

$$w_{k+1}=w_k-\frac{\eta_k}{m}\sum_{i}(w_kx_i+b_k-y_i)x_i, \tag{4.5}$$

$$b_{k+1}=b_k-\frac{\eta_k}{m}\sum_{i}(w_kx_i+b_k-y_i). \tag{4.6}$$

取 $D=\{(1,2),(2,4)\}$，以 $(w_0,b_0)=(0,0)$ 为初值，可算得 $\partial_w J=-5$、$\partial_b J=-3$。取 $\eta_0=0.1$，一步后参数为

$$(w_1,b_1)=(0.5,0.3). \tag{4.7}$$

这只是一次迭代的结果，而非最优解。将其代入损失函数，可以检查此次更新是否确实实现了下降。

4.4 学习率与一个可完整分析的例子

考虑一元二次目标

$$J(w)=(w-2)^2. \tag{4.8}$$

其唯一最小点为 $w_*=2$。因 $J'(w)=2(w-2)$，梯度下降满足

$$w_{k+1}-2=(1-2\eta)(w_k-2).$$

若学习率 η 固定，则递推得到

$$w_k-2=(1-2\eta)^k(w_0-2). \tag{4.9}$$

对任意初值的收敛充要条件为 $|1-2\eta|<1$，也就是

$$\boxed{0<\eta<1.} \tag{4.10}$$

$\eta=1/2$ 时，除初值已为最优点外，迭代一步即可到达 w_*；$\eta=1$ 时通常发生两点振荡；$\eta>1$ 时，除最优初值外，误差绝对值增大。这些判断只对当前目标成立，不能直接拿来作为一般优化问题的步长条件。

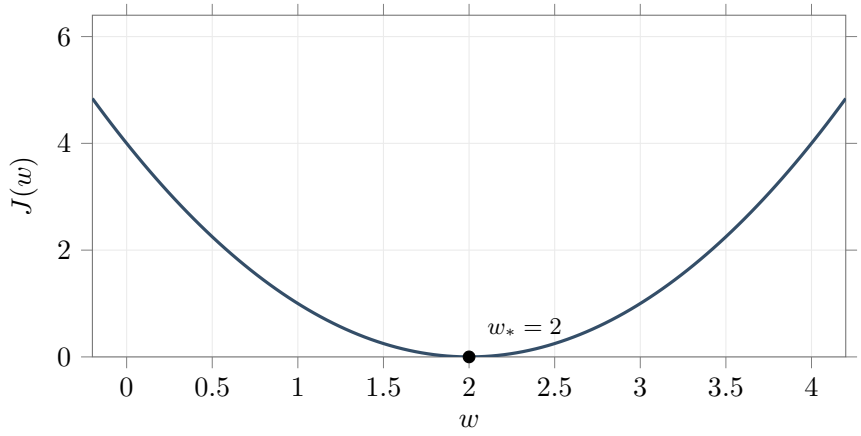


图 1: 二次目标 $J(w) = (w-2)^2$。曲线的极小点可以解析确定；梯度下降能否接近该点取决于步长。

4.5 一般光滑目标的下降估计

为了从简单例子走向一般结论，加入一个常见条件。

假设 4.1 (L-光滑)**.** 函数 J 连续可微，且存在常数 $L > 0$，使任意 $u, v \in \mathbb{R}^p$ 满足

$$\|\nabla J(u) - \nabla J(v)\|_2 \le L \, \|u - v\|_2 \, . \tag{4.11}$$

命题 4.2 (下降引理)**.** *在假设 4.1 下，任意 u, v 满足*

$$J(v) \le J(u) + \nabla J(u)^{\mathsf{T}}(v-u) + \frac{L}{2} \, \|v-u\|_2^2 \, . \tag{4.12}$$

证明. 令 $d = v - u$，定义 $g(t) = J(u + td)$。由微积分基本定理，

$$J(v) - J(u) = \int_0^1 \nabla J(u + td)^{\mathsf{T}} d \, \mathrm{d}t.$$

减去 $\nabla J(u)^{\mathsf{T}} d$，并利用 Cauchy–Schwarz 不等式及梯度的 Lipschitz 条件，

$$\begin{aligned} & J(v) - J(u) - \nabla J(u)^{\mathsf{T}} d \\ &= \int_0^1 [\nabla J(u + td) - \nabla J(u)]^{\mathsf{T}} d \, \mathrm{d}t \\ &\le \int_0^1 Lt \, \|d\|_2^2 \, \mathrm{d}t = \frac{L}{2} \, \|d\|_2^2 \, . \end{aligned}$$

即得结论。 □

在式 (4.12) 中令 $v = u - \eta \nabla J(u)$，得到

$$J(u - \eta \nabla J(u)) \le J(u) - \eta \left(1 - \frac{L\eta}{2}\right) \|\nabla J(u)\|_2^2 \, . \tag{4.13}$$

因而当 $0 < \eta < 2/L$ 时，若梯度非零，右侧严格小于 $J(u)$。特别是 $\eta \le 1/L$ 时有便于使用的下降下界。**函数值下降并不单独保证迭代点收敛到全局最优点**；要得出更强结论，还需要目标函数的下界、凸性或其他条件。

4.6 凸性、驻点与全局最优

若 J 是可微凸函数，则其一阶条件为

$$J(v) \geq J(u) + \nabla J(u)^{\mathsf{T}}(v-u).$$

因此 $\nabla J(u_*) = 0$ 蕴含 $J(v) \geq J(u_*)$ 对任意 v 成立，即 u_* 是全局最小点。反之，对于定义在整个 $\mathbb{R}^p$ 上的可微函数，任意局部极小点均满足梯度为零。两者合起来说明：*对于无约束可微凸优化，驻点与全局最小点等价。*

非凸情形不能照搬这一结论。例如 $J(w) = -w^2$ 在 $w = 0$ 处梯度为零，但该点是局部最大点。实际算法分析必须说明所用结论属于哪一类目标函数。

4.7 后续扩展

当前主要使用固定步长讨论梯度下降。今后可以补充精确线搜索、回溯线搜索、强凸函数的线性收敛，以及牛顿法、拟牛顿法与随机梯度方法，并比较每步代价和精度要求。

5 二分类的概率建模与对数损失

5.1 从线性得分到条件概率

考虑二分类标签 $Y \in \{0, 1\}$，线性得分 $z = x^{\mathsf{T}}\beta$ 可取任意实数，因此不能直接作为概率。逻辑回归使用 Logistic 函数

$$\sigma(z) = \frac{1}{1 + \mathrm{e}^{-z}} \tag{5.1}$$

把实数映射到开区间 $(0, 1)$，并定义

$$\pi(x) = \mathbb{P}(Y = 1 \mid X = x) = \sigma(x^{\mathsf{T}}\beta). \tag{5.2}$$

其中 x 可以含截距对应的常数分量。这里采用 π 表示条件概率，以免与特征维数 p 混淆。

由 (5.1) 可得

$$\frac{\pi(x)}{1 - \pi(x)} = \mathrm{e}^{x^{\mathsf{T}}\beta},$$

因此

$$\boxed{\log \frac{\pi(x)}{1 - \pi(x)} = x^{\mathsf{T}}\beta.} \tag{5.3}$$

模型对*对数几率*作线性建模。这也解释了 Logistic Regression 虽然沿用“回归”一词，却主要用于分类任务[1]第 3 章。

5.2 Sigmoid 的导数

对式 (5.1) 求导，

$$\sigma'(z) = -(1 + \mathrm{e}^{-z})^{-2}(-\mathrm{e}^{-z}) \tag{5.4}$$

$$= \frac{\mathrm{e}^{-z}}{(1 + \mathrm{e}^{-z})^2} \tag{5.5}$$

$$= \boxed{\sigma(z)[1 - \sigma(z)]}. \tag{5.6}$$

因此 Sigmoid 单调递增，且 $0 < \sigma'(z) \le 1/4$。**Sigmoid 并不是在整个实数轴上凸的**：其二阶导数符号在 $z = 0$ 两侧发生改变。逻辑回归的凸性来自负对数似然关于参数的结构，而非 Sigmoid 函数自身的全局凸性。

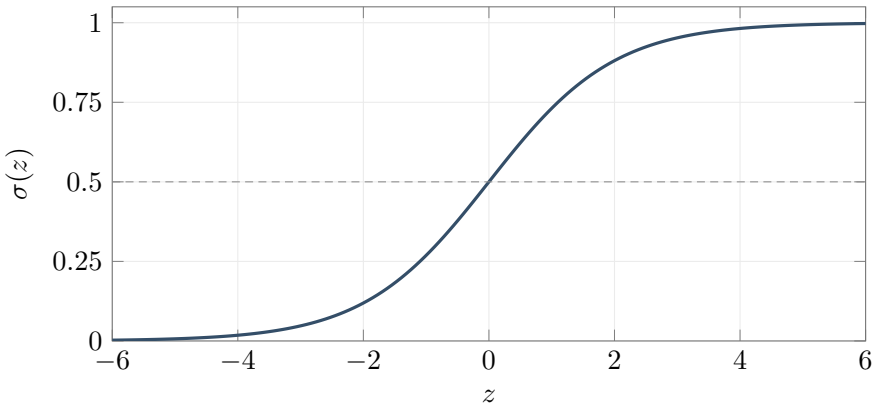


图 2: Logistic 函数将线性得分映射为二分类概率。$z = 0$ 时输出为 0.5。

5.3 伯努利似然与交叉熵

对样本 (x_i, y_i)，设 $Y_i \mid x_i \sim \text{Bernoulli}(\pi_i)$，其中 $\pi_i = \sigma(x_i^\top \beta)$。在给定输入后，若样本标签条件独立，则条件似然为

$$\mathcal{L}(\beta) = \prod_{i=1}^{m} \pi_i^{y_i} (1 - \pi_i)^{1 - y_i}. \tag{5.7}$$

取对数、乘以负号并按样本平均，得到

$$\boxed{J(\beta) = -\frac{1}{m} \sum_{i=1}^{m} \left[y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i) \right].} \tag{5.8}$$

这是二元交叉熵，也是该伯努利模型的平均负对数似然。由此可见，在给定概率假设和独立性条件下，损失函数具有明确的统计来源，而不是仅凭曲线形状选择[2]第 6 章。

5.4 从链式法则推导梯度

先考虑一个样本，记

$$\ell = -y \log \pi - (1 - y) \log(1 - \pi), \quad \pi = \sigma(z), \quad z = x^\top \beta.$$

对概率变量求导：

$$\frac{\partial \ell}{\partial \pi} = -\frac{y}{\pi} + \frac{1 - y}{1 - \pi} = \frac{\pi - y}{\pi(1 - \pi)}.$$

再利用式 (5.6)，

$$\frac{\partial \ell}{\partial z} = \frac{\partial \ell}{\partial \pi} \frac{\mathrm{d}\pi}{\mathrm{d}z} = \frac{\pi - y}{\pi(1 - \pi)} \pi(1 - \pi) = \pi - y.$$

由于 $\nabla_\beta z = x$，因此

$$\boxed{\nabla_\beta \ell = (\pi - y) x.} \tag{5.9}$$

把所有样本堆叠为设计矩阵 $X \in \mathbb{R}^{m \times p}$，定义概率向量 $\boldsymbol{\pi} = (\pi_1, \dots, \pi_m)^\top$，得到平均损失梯度

$$\boxed{\nabla J(\beta) = \frac{1}{m} X^\top (\boldsymbol{\pi} - y).} \tag{5.10}$$

这里的结构与最小二乘梯度 (3.9) 十分接近：都是先计算某种“预测与真实值之差”，再乘设计矩阵的转置。差别在于预测值和损失函数来自不同的概率或建模假设。

5.5 Hessian、凸性与例外情形

记 $W = \mathrm{diag}\{\pi_i(1-\pi_i)\}_{i=1}^m$，则

$$\nabla^2 J(\beta) = \frac{1}{m} X^\mathsf{T} W X. \tag{5.11}$$

对任意 v，

$$v^\mathsf{T}\nabla^2 J(\beta) v = \frac{1}{m}(Xv)^\mathsf{T} W (Xv) \geq 0,$$

所以在常规无正则化二分类逻辑回归中，平均负对数似然关于 β 是凸函数。对所有有限参数，$\pi_i \in (0,1)$，故 W 的对角元素严格为正；若 X 满列秩，则 Hessian 正定。

但是正定 Hessian 并不自动保证有限的极小点存在。例如样本线性完全可分时，沿某些参数方向把系数绝对值持续放大，可以使负对数似然逼近下确界 0，而无正则化极大似然估计可能不存在有限解。因而“凸”与“存在唯一有限最优解”是不同的判断。

5.6 一次相容的手工更新

设单个样本 $x = 1$、$y = 1$，初始 $w_0 = b_0 = 0$，模型为 $\pi = \sigma(wx + b)$。此时 $z = 0$、$\pi = 1/2$，因此

$$\frac{\partial \ell}{\partial w} = (1/2 - 1)\cdot 1 = -1/2, \qquad \frac{\partial \ell}{\partial b} = -1/2.$$

取学习率 $\eta = 0.1$，同步更新后

$$(w_1, b_1) = (0.05, 0.05). \tag{5.12}$$

这个例子特意从给定参数重新计算概率，避免出现“人为指定的概率值”与 Sigmoid 模型不一致的问题。概率预测若需要转为类别，还须另外声明分类阈值及相应的决策代价。

5.7 模型解释与适用范围

在其他特征固定时，某个系数 β_j 增加一单位特征对应的对数几率变化为 β_j；对应的几率乘以 e^{β_j}。这一解释针对模型规定的条件几率，并不能仅凭相关性就作因果推断。样本不平衡、特征高度相关、概率校准等问题留待后续专题讨论。

6 模型评价、过拟合与泛化分析

6.1 评价对象：训练误差与总体风险

经验风险最小化直接控制的是既有样本上的误差；模型的实际用途通常是对尚未见过的输入进行预测。设训练集为 D，经训练得到函数 $\hat{f}_D$。在平方损失下，训练误差可写为

$$\mathrm{MSE}_{\mathrm{train}} = \frac{1}{m}\sum_{i=1}^{m}\big(y_i - \hat{f}_D(x_i)\big)^2. \tag{6.1}$$

对应的总体预测风险则是

$$R(\hat{f}_D) = \mathbb{E}_{(X,Y)\sim P}\left[\big(Y - \hat{f}_D(X)\big)^2 \mid D\right]. \tag{6.2}$$

式 (6.2) 对训练集 D 作条件化，以强调：一旦训练完成，$\hat{f}_D$ 已固定，而新观测来自目标数据分布。我们通常不知道 P，因此不能直接计算该期望，只能借助未参与拟合的样本作估计。训练误差低不意味着式 (6.2) 必然低[1]第 2 章。

6.2 欠拟合、过拟合与模型复杂度

模型容量不足时可能出现欠拟合：即使已充分优化训练目标，也无法表示数据中的主要关系。相反，复杂模型可能捕捉训练集特有的随机波动，使训练损失非常小，而对新数据的预测并不可靠；这属于过拟合的典型表现。两种情况须结合训练集和独立评价集的误差理解，而不能只看参数量或者拟合曲线的形状。

多项式回归能够提供一个直观例子：

$$\hat{f}_d(x) = \sum_{j=0}^{d} \beta_j x^j. \tag{6.3}$$

对于嵌套多项式函数族，如果每个次数对应的优化问题都被求得全局最小训练平方损失，则增加次数不会增大训练集上的最优 *RSS*。然而，测试误差没有类似的单调性保证。先前练习记录中，一组不同次数模型的误差如下，数据应视为待核验的历史实验记录，而非本次独立重新运行的结果。

表 1: 多项式复杂度对拟合结果的影响：先前练习记录

次数 d	训练 MSE	测试 MSE	观察
1	0.1869	0.1740	模型表达能力可能不足
8	0.0368	0.0359	本组数据中测试误差较低
25	0.0269	0.2600	训练误差仍低，测试误差明显升高

这里的判断是针对给定样本划分的经验观察。对于真实总体风险的比较，还需要讨论抽样不确定性及结果可重复性。不能把一次测试集上的数值差异直接解释为关于所有数据分布的数学定理。

6.3 平方误差下的偏差—方差分解

考察固定输入 x_0 的新观测

$$Y_0 = f(x_0) + \varepsilon_0. \tag{6.4}$$

假设 $\mathbb{E}[\varepsilon_0] = 0$、$\mathrm{Var}(\varepsilon_0) = \sigma^2$，且 ε_0 独立于用于训练 $\hat{f}_D$ 的数据。训练集 D 随机变化时，$\hat{f}_D(x_0)$ 也是随机变量。定义

$$\mathrm{Bias}\big(\hat{f}_D(x_0)\big) = \mathbb{E}_D[\hat{f}_D(x_0)] - f(x_0), \tag{6.5}$$

$$\mathrm{Var}\big(\hat{f}_D(x_0)\big) = \mathbb{E}_D\left[\big(\hat{f}_D(x_0) - \mathbb{E}_D\hat{f}_D(x_0)\big)^2\right]. \tag{6.6}$$

命题 6.1 (固定输入处的偏差—方差分解)**.** *在上述条件以及有关二阶矩存在的前提下，*

$$\boxed{\mathbb{E}_{D,\varepsilon_0}\big[(Y_0 - \hat{f}_D(x_0))^2\big] = \mathrm{Bias}\big(\hat{f}_D(x_0)\big)^2 + \mathrm{Var}\big(\hat{f}_D(x_0)\big) + \sigma^2.} \tag{6.7}$$

证明. 令 $\mu = \mathbb{E}_D[\hat{f}_D(x_0)]$，则

$$Y_0 - \hat{f}_D(x_0) = \underbrace{f(x_0) - \mu}_{\text{常数}} + \underbrace{\mu - \hat{f}_D(x_0)}_{\text{均值为零}} + \underbrace{\varepsilon_0}_{\text{均值为零}}.$$

对等式两边平方并取期望。由于两项随机量均值为零，且 ε_0 与训练集独立，三个交叉项的期望为零，因此

$$\begin{aligned}\mathbb{E}\big[(Y_0-\hat f_D(x_0))^2\big] &= \big(f(x_0)-\mu\big)^2+\mathbb{E}_D\big[(\hat f_D(x_0)-\mu)^2\big]+\mathbb{E}[\varepsilon_0^2]\\ &= \mathrm{Bias}\big(\hat f_D(x_0)\big)^2+\mathrm{Var}\big(\hat f_D(x_0)\big)+\sigma^2.\end{aligned}$$

□

分解式 (6.7) 展示三种不同来源：模型估计的系统性偏差、训练数据扰动引起的方差，以及在当前输入信息下无法消除的随机噪声。通常较灵活的函数族可以降低逼近偏差，却也可能使估计对有限样本更加敏感；具体变化须结合问题和算法验证[3]第 2 章。这里讨论的是平方损失，不应无条件推广到准确率或所有其他指标。

6.4 留出法与交叉验证

最简单的评价方法是将数据分为训练集 D_{tr} 与测试集 D_{te}。对需要选择模型复杂度和超参数的实验，通常还应设置验证数据，或者在训练部分内部进行交叉验证。测试集主要负责最终评价，不应用于反复选择模型。

在 K 折交叉验证中，将训练数据划分为不重叠的 K 份 $D_1,\dots,D_K$。每次用其余 $K-1$ 份训练，在 D_k 上记录平均损失 E_k。当各折大小相同时，

$$\mathrm{CV}(K)=\frac{1}{K}\sum_{k=1}^{K}E_k. \tag{6.8}$$

若各折样本数 m_k 不完全相同，且需要计算所有折外预测损失的样本平均，则应使用

$$\mathrm{CV}_{\mathrm{weighted}}=\frac{\sum_{k=1}^{K}m_kE_k}{\sum_{k=1}^{K}m_k}. \tag{6.9}$$

5 折、10 折是常见选择，但并非对所有数据都最优。分折方式应尊重数据的依赖结构：时间序列、同一受试者重复观测、按组聚集的数据，都可能需要特殊的分割方法[3]第 5 章。

除样本直接交叉出现外，还应注意预处理引起的数据泄漏。标准化系数、缺失值填补规则、特征选择等，只能在每一轮的训练折上拟合，再应用于对应验证折；不能预先用所有数据计算，然后再进行交叉验证。

6.5 二分类的常用评价指标

表 2: 二分类混淆矩阵

	实际正类	实际负类
预测正类	TP	FP
预测负类	FN	TN

在相应分母非零时，准确率、精确率、召回率与 F_1 分数定义为

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \tag{6.10}$$

$$\text{Precision} = \frac{TP}{TP + FP}, \tag{6.11}$$

$$\text{Recall} = \frac{TP}{TP + FN}, \tag{6.12}$$

$$F_1 = \frac{2\,\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN}. \tag{6.13}$$

当类别比例严重不平衡时，Accuracy 可能掩盖正类识别能力。例如 100 个样本仅有 5 个正类，若全部预测为负类，准确率仍是 95%，但召回率为零。指标选择必须结合漏报、误报及实际决策代价。

6.6 评价结果的统计解释

测试误差只是总体风险的估计量。单次随机划分得到的数值并不天然具有很强的稳定性。在比较模型时，可以重复合理的数据划分或报告多折表现的变动；更重要的是说明抽样单位、是否存在数据泄漏以及评价指标的适用前提。若模型经过多轮调参，最终测试集应保持独立，避免选择偏差。对于分布漂移等情形，上述方法所估计的目标风险可能不再等同于实际部署风险。

7 数值计算与实验记录

本节区分两种内容：*解析可核对的算例*与*需要实际执行代码的实验*。前者给出可逐项检查的数值，后者保留脚本、运行环境与后续扩展位置。实验结论不只取决于图形是否美观，还取决于数据生成方式、训练方案和比较标准。

7.1 一元线性回归的解析核对

对数据

$$(x_1, y_1) = (1, 2), \quad (x_2, y_2) = (2, 3), \quad (x_3, y_3) = (3, 5),$$

有 $\bar{x} = 2$、$\bar{y} = 10/3$，以及

$$\sum_i (x_i - \bar{x})^2 = 2, \qquad \sum_i (x_i - \bar{x})(y_i - \bar{y}) = 3.$$

据式 (3.7)，最小二乘估计为

$$\hat{w} = \frac{3}{2}, \qquad \hat{b} = \frac{1}{3}. \tag{7.1}$$

预测值依次为 $11/6, 10/3, 29/6$，残差依次为 $1/6, -1/3, 1/6$。因此

$$\text{RSS} = \frac{1}{6}, \qquad \text{MSE} = \frac{1}{18}. \tag{7.2}$$

计算过程中必须明确：样本数为 3，而目标函数 $J = \text{RSS}/(2m)$ 与评价指标 MSE 的缩放系数不同。此例可以用来对照正规方程、解析公式与梯度下降的结果。

7.2 NumPy 实现与结果比较

源码存放在 `code/linear_regression_demo.py`。程序分别用 `numpy.linalg.lstsq` 与自行实现的全批量梯度下降求解同一个问题，初始系数为零。其主要计算部分如下：

Listing 1: 最小二乘与梯度下降的参数估计代码

```
x = np.array([1.0, 2.0, 3.0])
y = np.array([2.0, 3.0, 5.0])
X = np.column_stack([x, np.ones_like(x)])
m = len(y)

# The coefficient order is [slope, intercept].
beta_lstsq, _, _, _ = np.linalg.lstsq(X, y, rcond=None)

# Minimize J(beta) = ||X @ beta - y||^2 / (2 * m).
eta = 0.1
beta = np.zeros(2)
for iteration in range(5000):
    error = X @ beta - y
    gradient = X.T @ error / m
    beta = beta - eta * gradient
```

这里采用每轮全数据梯度，因此更新式对应 (3.9)。对于本例，步长设置为 0.1；若更换数据或特征尺度，必须重新检查这个步长是否合理。实验输出与解析结果应在数值误差允许的范围内一致；单次运行的详细记录由源码旁的日志另行维护。

7.3 逻辑回归的梯度一致性检查

逻辑回归脚本 `code/logistic_gradient_check.py` 使用中心差分近似数值梯度，并和式 (5.10) 的解析梯度比较。对于参数分量 β_j，中心差分为

$$\frac{\partial J}{\partial \beta_j} \approx \frac{J(\beta + h e_j) - J(\beta - h e_j)}{2h}, \tag{7.3}$$

其中 $h > 0$ 很小，e_j 是第 j 个标准基向量。若误差明显大于合理的数值尺度，应检查梯度符号、样本平均系数及数据矩阵维数。数值梯度检查不是理论证明，但很适合排除程序实现错误。

7.4 实验记录规范

后续实验均建议至少写明：数据来源或生成机制、样本数量与特征维数、训练/验证/测试划分、随机种子、损失函数、优化方法、主要超参数、评价指标以及计算环境。除报告最优成绩外，也应保存不符合预期的结果；这些异常往往更有助于识别模型设定或程序错误。

表 3: 实验登记表（后续按需要续填）

主题	状态	下一步工作
线性回归	解析结果已核对	对比梯度法、最小二乘和不同特征尺度
逻辑回归	公式推导已完成	核对解析梯度与数值梯度，记录拟合结果
多项式拟合	已有历史示例	补齐原始数据、随机种子与可重复脚本

8 讨论与后续研究方向

8.1 从最小化训练风险到控制模型复杂度

前述方法主要研究给定模型族内的参数求解。对于模型选择和泛化能力，仍需要考察正则化的作用。一个自然的扩展是

$$\min_{\theta}\left\{\frac{1}{m}\sum_{i=1}^{m}L\big(y_i,f_\theta(x_i)\big)+\lambda\Omega(\theta)\right\},\qquad \lambda\geq 0. \tag{8.1}$$

$\Omega(\theta)$ 用于表达偏好的参数结构或复杂度，λ 调节经验拟合与附加约束之间的权衡。岭回归、Lasso 及其相关优化条件是这一方向的后续重点，现阶段不将尚未讨论的收敛性或泛化效果当作既定结论。

8.2 从解析方法到一般数值优化

最小二乘目标的 Hessian 为 $X^{\mathsf{T}}X/m$，其凸性和条件数会直接影响数值求解。今后应进一步比较正规方程、QR/SVD 分解、梯度下降、线搜索和牛顿类方法：哪些方法依赖凸性，哪些方法能处理不可微目标，何时需要考虑约束，以及计算规模如何影响算法选择。对于具备二次规划结构的问题，还可以适当考察专用优化求解器的作用，但不应以求解器替代数学证明。

8.3 从点估计到统计推断

最小二乘系数作为点估计后，还可进一步研究其偏差、方差与区间估计。相关结论需要区分模型形式、误差条件、设计矩阵秩条件以及是否将输入视为随机变量。尤其应避免把“估计系数显著”与“预测效果好”直接等同。

8.4 仍需回答的问题

1. 对同一个预测任务，不同损失函数分别隐含怎样的统计假设和决策偏好？
2. 对于凸但不强凸的目标，梯度下降在何种条件下有函数值收敛率？
3. 当样本数接近或小于特征数时，最小二乘估计的不唯一性如何影响泛化？
4. 当训练与测试数据并非来自同一分布时，现有交叉验证流程需要怎样调整？

这些问题将在后续专题中分别展开，而不是在本节提前给出没有证明条件的统一回答。

A 主要符号及约定

符号	含义
m	训练样本数量。
p	参数维数；在具体任务中应与特征维数的约定相区分。
(x_i,y_i)	第 i 个输入与目标观测。
D	训练数据集。

符号	含义
$\mathcal{F}$	候选预测函数或模型族。
f_θ	由参数 θ 指定的预测函数。
$L(y,\hat{y})$	单个样本的损失函数。
$\widehat{R}_D(f)$	数据集 D 上的经验风险。
$R(f)$	在目标分布下的期望风险。
$J(\theta)$	需要最小化的目标函数；其尺度按上下文给出。
$X \in \mathbb{R}^{m\times p}$	设计矩阵。与截距相关的常数列可包含在内。
θ, β	模型参数向量，选用何者应在相应公式附近说明。
$\nabla J, \nabla^2 J$	目标函数的梯度与 Hessian 矩阵。
η_k	第 k 次迭代所采用的学习率。
$\pi(x)$	逻辑回归中正类的条件概率。
TP, FP, FN, TN	二分类混淆矩阵的四种计数。
$\mathbb{E}$, Var, Bias	期望、方差与偏差。
$\|v\|_2$	向量 v 的欧氏范数。

除非另行说明，文中向量按列向量处理，转置记作 $^\mathsf{T}$。对符号相同但假设不同的结论，应在首次使用时重新说明适用范围。文中所称“最优解”通常是训练目标意义上的最优解，而不是泛化风险意义上的最优解。

B 修订记录

日期	版本	修订内容
2026-11	v0.1	建立可持续扩展的文稿；整理学习框架、最小二乘、梯度下降、逻辑回归、模型评价及基础数值实验。

后续增加模型或更改公式时，应在此记录改动原因；出现教材间的符号或结论差异时，优先保留各自成立的假设，再进行比较。

参考文献

[1] 周志华. 机器学习[M]. 清华大学出版社, 2016.

[2] 李航. 统计学习方法[M]. 2 版. 清华大学出版社, 2019.

[3] James G, Witten D, Hastie T, Tibshirani R, Taylor J. An Introduction to Statistical Learning: With Applications in Python[M/OL]. Springer, 2023. DOI: 10.1007/978-3-031-38747-0.

[4] 刘浩洋, 户将, 李勇锋, 文再文. 最优化计算方法（简化版）[M]. 2020.