机器学习：从直观例子到公式推导

天国　付

2026 年 11 月

摘要

本文系统介绍机器学习的基本概念、线性回归与最小二乘估计、梯度下降法、逻辑回归以及模型评估与泛化。首先通过典型数据说明建模对象和损失函数，再从具体计算推导参数估计与迭代更新公式，进而讨论训练误差与测试误差的区别、交叉验证及常用评价指标。各部分在给出数学表达式时说明相关符号与适用条件，并结合数值算例展示计算过程。

关键词：机器学习；均方误差；线性回归；梯度下降；逻辑回归；泛化能力

目录

1　机器学习基础 **2**

2　线性回归与最小二乘法 **5**

3　梯度下降法 **8**

4　逻辑回归与二分类 **11**

5　过拟合、泛化与模型评价 **15**

A　常用数学符号 **19**

B　修订记录 **20**

参考文献 **20**

1 机器学习基础

1.1 机器学习的基本思想

如果需要判断一个西瓜是不是好瓜，最直接的办法是提前写出规则，例如“色泽青绿且敲声浊响就判为好瓜”。但规则是谁给计算机的？是程序员。现实情况可能远比一两条规则复杂：同样的颜色可能对应不同结果，根蒂、纹理等信息也会影响判断。

另一种方法是先收集已经知道结果的样本，让程序从这些样本中建立预测规则。机器学习研究的正是如何利用已有数据，得到能对新数据进行预测或分析的模型。这里的关键不是“让计算机记住答案”，而是希望它学到能够用于未见数据的规律。

表 1: 为了说明概念而构造的西瓜样本

色泽	根蒂	敲声	已知结果
青绿	蜷缩	浊响	好瓜
乌黑	蜷缩	浊响	好瓜
浅白	硬挺	清脆	坏瓜
青绿	硬挺	清脆	坏瓜

1.2 样本、特征与标记

先换成更容易用数学表达的例子：根据每天的学习时间预测成绩。假设记录了四名学生：

学生	学习时间 x（小时）	成绩 y（分）
A	1	60
B	2	70
C	3	80
D	4	90

每一行叫作一个**样本**；学习时间是用于预测的**特征**（输入 x）；已知成绩是**标记**或响应变量（输出 y）。

若有 m 个样本，就可将训练数据写为

$$\boxed{D = \{(x_i, y_i)\}_{i=1}^{m}.} \tag{1.1}$$

i 表示第几个样本，而非指数。如果每个样本包含 d 个数值特征，如学习时间、出勤率和作业得分，则输入变成列向量

$$\boldsymbol{x}_i = (x_{i1}, x_{i2}, \ldots, x_{id})^{\mathsf{T}} \in \mathbb{R}^d.$$

1.3 学习任务的基本分类

监督学习的训练样本提供了待预测的正确结果。例如已有学习时间和真实成绩，便可以训练成绩预测模型。**无监督学习**通常没有这样的目标标记，算法可能根据学习时间与娱乐时间等信息把学生分组；聚类就是一种典型任务。所谓“无监督”不是“没有数据”，而是没有提供任务对应的目标标记。

监督学习常见两种任务：

任务	预测目标	例子
回归（Regression）	连续数值	房价、气温、成绩
分类（Classification）	离散类别	邮件是否为垃圾邮件

这是按**预测目标**划分任务，而不是按程序使用了哪种求解器划分。

1.4 模型、参数、策略与算法

假设先使用一条过原点的直线预测：

$$\boxed{\hat{y} = wx.} \tag{1.2}$$

$\hat{y}$ 表示预测值；x 是输入；w 是**模型参数**，决定这条直线的斜率。若 $w = 5$，则学习两小时预测 10 分；若 $w = 10$，则预测 20 分。改变 w，模型的预测规则就变了。

现在允许直线有截距：

$$\hat{y} = wx + b, \qquad w, b \in \mathbb{R}.$$

所有这种形式的函数构成一个**模型族**（或假设空间）：

$$\mathcal{F} = \{f_{w,b}(x) = wx + b \mid w, b \in \mathbb{R}\}. \tag{1.3}$$

模型族告诉我们允许使用什么形式的函数；**参数**决定最终是哪一条直线；**算法**负责从数据中寻找合适参数。

李航《统计学习方法》常用“模型—策略—算法”概括这件事：模型规定学什么，策略规定什么算好，算法规定怎么求出来[1]第 1 章。

1.5 预测误差与损失函数

用三组数据：

$$(x_1, y_1) = (1, 2), \quad (x_2, y_2) = (2, 4), \quad (x_3, y_3) = (3, 6).$$

采用模型 $\hat{y} = wx$，如果先猜 $w = 1$，预测就是 $(1, 2, 3)$，而真实结果为 $(2, 4, 6)$。我们需要衡量预测与真实值之间的差别。

单个样本的预测误差可写成 $e_i = \hat{y}_i - y_i$；仅将误差直接相加可能发生正负抵消，因此常把误差平方，定义**平方损失**

$$\boxed{L(y_i, \hat{y}_i) = (y_i - \hat{y}_i)^2.} \tag{1.4}$$

例如真实值为 4、预测值为 2，损失为 $(4-2)^2 = 4$；如果预测改为 3，损失降为 1。平方使较大的误差受到更大惩罚，但也意味着这种方法对离群值可能较敏感。

将所有样本的平方损失求平均，得到**均方误差**（MSE）：

$$\boxed{\mathrm{MSE}(w) = \frac{1}{m}\sum_{i=1}^{m}(wx_i - y_i)^2.} \tag{1.5}$$

辨别三个量： L 衡量一个样本；MSE 衡量这批样本的平均平方误差；w 是使误差发生变化、等待求解的参数。

1.6 参数估计的基础算例

把三个样本代入，设 $J(w)=\mathrm{MSE}(w)$，便有

$$J(w)=\frac{1}{3}\left[(w-2)^2+(2w-4)^2+(3w-6)^2\right] \tag{1.6}$$

$$=\frac{1}{3}(1+4+9)(w-2)^2 \tag{1.7}$$

$$=\frac{14}{3}(w-2)^2. \tag{1.8}$$

平方永远非负，所以当且仅当 $w=2$ 时，J 最小且等于 0：

$$\boxed{w^*=2,\qquad J(w^*)=0,\qquad \hat{y}=2x.} \tag{1.9}$$

这是一个完整的训练过程：**提供数据 → 选择模型 → 定义损失 → 确定参数**。

上述参数估计过程写成优化问题，即

$$\min_{w\in\mathbb{R}} J(w).$$

$\min J$ 指的是最小函数值；$\arg\min J$ 指的是让函数取得最小值的参数。在这里，最小值是 0，而使它最小的参数是 $w=2$。要注意区分。

1.7 经验风险最小化

上面 MSE 是一种具体的损失。若把损失函数统一写为 L，模型统一写为 f，则训练样本上的**经验风险**为

$$\widehat{R}_D(f)=\frac{1}{m}\sum_{i=1}^{m}L(y_i,f(x_i)). \tag{1.10}$$

在平方损失和 $f_w(x)=wx$ 的情况下，它恰好就是前面算过的 MSE。选择使平均损失最小的模型叫作**经验风险最小化**（ERM）：

$$\hat{f}\in\arg\min_{f\in\mathcal{F}}\widehat{R}_D(f). \tag{1.11}$$

1.8 训练误差与泛化能力

刚才 $f(x)=2x$ 完全拟合三条训练记录。但另一个函数

$$g(x)=2x+(x-1)(x-2)(x-3)$$

也在 $x=1,2,3$ 时分别预测 $2,4,6$，因为乘积中总有一个因子为零。

可是面对没有见过的 $x=4$，两者预测为

$$f(4)=8,\qquad g(4)=8+3\times2\times1=14.$$

同样的零训练误差，并不意味着相同的未来预测。这就是为什么评估模型时不能只检查训练数据。

如果假设新数据来自某个目标联合分布 $P_{X,Y}$，便可用**总体风险**描述平均预测损失：

$$R(f)=\mathbb{E}_{(X,Y)\sim P_{X,Y}}[L(Y,f(X))]. \tag{1.12}$$

当前不要求直接计算这条式子。$\mathbb{E}$ 表示按目标数据分布求期望；它与把固定训练集上若干损失直接求平均不同。真实数据分布通常未知，因此我们会用独立测试数据估计预测表现。

2 线性回归与最小二乘法

2.1 线性回归的建模背景

以上的三组数据恰好满足 $y = 2x$，训练误差可以达到零。现实数据往往并不这样整齐。考虑四组数据：

学生	学习时间 x（小时）	成绩 y（教学数值）
A	1	2
B	2	3
C	3	5
D	4	4

如果用一条直线近似这些点，哪条直线算“最好”？线性回归提供函数形式，最小二乘法提供选择直线参数的准则。这里的成绩是人工数据，并不是实际考试成绩。

2.2 一元线性模型与参数

假设输入和输出之间近似满足

$$\boxed{\hat{y}_i = wx_i + b.} \tag{2.1}$$

x_i 是第 i 个输入，y_i 是真实结果，$\hat{y}_i$ 是预测结果；w 是斜率（权重），b 是截距（偏置）。输入和真实结果属于数据，w, b **才是需要由训练确定的参数**。

例如随手选择 $w = 1, b = 1$，模型就是 $\hat{y} = x + 1$。当 $x = 3$ 时预测为 4，而样本真实结果是 5。这说明需要有一套评价参数好坏的规则。

2.3 残差、平方和与均方误差

定义**残差**为

$$e_i = y_i - \hat{y}_i = y_i - (wx_i + b). \tag{2.2}$$

在 $w = 1, b = 1$ 的情况下，四个样本有

x_i	y_i	$\hat{y}_i$	e_i
1	2	2	0
2	3	3	0
3	5	4	1
4	4	5	-1

残差相加得到 $0 + 0 + 1 - 1 = 0$，但模型显然没有预测对全部样本。为了避免正负抵消，使用残差平方和（RSS）衡量整体拟合误差：

$$\mathrm{RSS}(w, b) = \sum_{i=1}^{n} (y_i - wx_i - b)^2. \tag{2.3}$$

将 RSS 除以样本数 n，就是**均方误差**：

$$\boxed{\mathrm{MSE}(w, b) = \frac{1}{n} \sum_{i=1}^{n} (wx_i + b - y_i)^2.} \tag{2.4}$$

对于这四条数据，当前 MSE $= (0+0+1+1)/4 = 0.5$。最小二乘法要求找到 w, b，使 RSS（等价地，使 MSE）最小。

2.4 训练目标函数的缩放

为了计算方便，训练时还常写

$$\boxed{J(w,b) = \frac{1}{2n}\sum_{i=1}^{n}(wx_i + b - y_i)^2.} \tag{2.5}$$

它和 MSE 相比多乘了 $1/2$：MSE $= 2J$。例如，前面临时取 $w = 1, b = 1$ 时，MSE 为 0.5，对应的 J 就是 0.25。如果另取参数使 MSE 降到 0.45，则对应 $J = 0.225$。无论比较 MSE 还是 J，参数的优劣次序都没有改变。**数值不同，但取到最小值的 w, b 完全相同**。加上 $1/2$ 只是为了消掉平方求导产生的系数 2。不能把 J 的数值直接称为 MSE。

现在要解决的问题可以写成

$$\min_{w,b\in\mathbb{R}} J(w,b).$$

这就是一个二元函数的极小化问题。

2.5 最小二乘估计：截距

符号 $\partial J/\partial b$ 表示在其他变量保持不变时，目标函数 J 对参数 b 的偏导数。求导时，将 w、x_i 和 y_i 视为常数。对每个平方项使用链式法则：

$$\frac{\partial}{\partial b}(wx_i + b - y_i)^2 = 2(wx_i + b - y_i)\frac{\partial(wx_i + b - y_i)}{\partial b} = 2(wx_i + b - y_i).$$

将各项相加，再乘以目标函数中的 $1/(2n)$，得到

$$\frac{\partial J}{\partial b} = \frac{1}{n}\sum_{i=1}^{n}(wx_i + b - y_i). \tag{2.6}$$

令它等于 0，先展开求和，再两边除以 n：

$$\begin{aligned}\sum_{i=1}^{n}(wx_i + b - y_i) &= 0,\\ w\sum_{i=1}^{n}x_i + nb - \sum_{i=1}^{n}y_i &= 0,\\ w\bar{x} + b - \bar{y} &= 0.\end{aligned}$$

这里

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n}x_i, \qquad \bar{y} = \frac{1}{n}\sum_{i=1}^{n}y_i$$

分别是输入、输出的样本均值。所以

$$\boxed{b = \bar{y} - w\bar{x}.} \tag{2.7}$$

得到：**带截距项的普通最小二乘直线经过均值点** $(\bar{x}, \bar{y})$。

2.6 最小二乘估计：斜率

现在把 b 看成常数，有

$$\frac{\partial J}{\partial w} = \frac{1}{n}\sum_{i=1}^{n} x_i(wx_i + b - y_i). \tag{2.8}$$

令偏导为零，并代入刚求得的 $b = \bar{y} - w\bar{x}$：

$$\sum_{i=1}^{n} x_i\big[w(x_i - \bar{x}) - (y_i - \bar{y})\big] = 0.$$

因为 $\sum_i (x_i - \bar{x}) = 0$、$\sum_i (y_i - \bar{y}) = 0$，整理得

$$w\sum_{i=1}^{n}(x_i - \bar{x})^2 = \sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}).$$

只要 x_i 不全部相同，分母就大于零，于是得到熟悉的最小二乘公式：

$$\boxed{\hat{w} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}, \qquad \hat{b} = \bar{y} - \hat{w}\bar{x}.} \tag{2.9}$$

回到开头的样本，先求均值：

$$\bar{x} = \frac{1+2+3+4}{4} = 2.5, \qquad \bar{y} = \frac{2+3+5+4}{4} = 3.5.$$

然后列一个表核对斜率的分子和分母：

$x_i - \bar{x}$	$y_i - \bar{y}$	两者乘积	$(x_i - \bar{x})^2$
-1.5	-1.5	2.25	2.25
-0.5	-0.5	0.25	0.25
0.5	1.5	0.75	0.25
1.5	0.5	0.75	2.25
	合计	4	5

因此

$$\hat{w} = \frac{4}{5} = 0.8, \qquad \hat{b} = 3.5 - 0.8 \times 2.5 = 1.5.$$

最终拟合直线为

$$\boxed{\hat{y} = 0.8x + 1.5.} \tag{2.10}$$

在四个训练点上，其预测值分别为 $2.3, 3.1, 3.9, 4.7$；平方误差为 $0.09, 0.01, 1.21, 0.49$。故

$$\boxed{\text{MSE} = \frac{0.09 + 0.01 + 1.21 + 0.49}{4} = 0.45.}$$

和刚才的 $w = 1, b = 1$ 时的 0.5 相比，训练误差确实降低了。

若代入新输入 $x = 5$，预测 $\hat{y} = 0.8 \times 5 + 1.5 = 5.5$。它是模型给出的数学预测，不是真实成绩；而且 5 超出了训练输入的范围 $[1, 4]$，这种预测属于**外推**，需要格外谨慎。

2.7 最优解的存在与唯一性

对于一般二元函数，偏导数为零只是驻点条件，并不自动意味着极小值。这里不同：$J(w, b)$ 是若干平方项之和，是关于参数的**凸二次函数**。若输入不全相同，含截距的两个参数可以唯一确定，因此上面的解是全局最小点。若所有 x_i 相同，斜率无法被唯一识别。

2.8 多元线性回归的矩阵形式

若每个样本有很多特征，可将设计矩阵写成 $X \in \mathbb{R}^{n\times p}$，参数向量写成 $\boldsymbol{\beta} \in \mathbb{R}^p$，输出写成 $\boldsymbol{y} \in \mathbb{R}^n$。为了处理截距，可在 X 中增加一列全 1。

平方损失的矩阵形式为

$$J(\boldsymbol{\beta}) = \frac{1}{2n}\|X\boldsymbol{\beta} - \boldsymbol{y}\|_2^2,$$

对应梯度

$$\nabla J(\boldsymbol{\beta}) = \frac{1}{n}X^{\mathsf{T}}(X\boldsymbol{\beta} - \boldsymbol{y}). \tag{2.11}$$

令梯度为零得到**正规方程**：

$$X^{\mathsf{T}}X\hat{\boldsymbol{\beta}} = X^{\mathsf{T}}\boldsymbol{y}. \tag{2.12}$$

当 X 满列秩时，$X^{\mathsf{T}}X$ 可逆，于是

$$\hat{\boldsymbol{\beta}} = (X^{\mathsf{T}}X)^{-1}X^{\mathsf{T}}\boldsymbol{y}. \tag{2.13}$$

3 梯度下降法

3.1 梯度下降的基本思想

对于简单线性回归，可以使用最小二乘公式直接求出斜率和截距，但并不是每个机器学习模型都存在方便使用的解析解。遇到复杂的目标函数，可以先任选一个参数初值，计算当前位置的导数，向使目标函数减小的方向迈一小步，再重复这个过程。这就是**梯度下降法**（Gradient Descent）的基本思想。

3.2 一元函数的下降方向

设

$$f(x) = (x-3)^2. \tag{3.1}$$

由平方的非负性可知，$x = 3$ 时取得最小值 0。为分析函数值随 x 的变化，求其一阶导数：

$$f'(x) = 2(x-3).$$

- 当 $x < 3$ 时，导数为负，适当**增大** x 有利于减小函数值。
- 当 $x > 3$ 时，导数为正，适当**减小** x 有利于减小函数值。

两个情况用一个更新公式统一表示：

$$\boxed{x_{\text{新}} = x_{\text{旧}} - \eta f'(x_{\text{旧}}), \qquad \eta > 0.} \tag{3.2}$$

η 是**学习率**。例如在 $x = 1$ 时导数为 -4：减去一个负数会让 x 增大，正好朝 3 的方向移动；如果当前位置换成 $x = 4$，导数变为 2，减去正数就会让 x 减小。两种更新都朝同一个最低点靠近，但一次移动多少还要由学习率决定。学习率控制一次更新移动多远，不能随便设得很大。为什么公式是减号？因为正导数需要往左走，负导数需要往右走，减去导数恰好同时满足这两点。

3.3 迭代计算

取初值 $x_0 = 1$，学习率 $\eta = 0.2$。第一次先算导数：

$$f'(1) = 2(1-3) = -4.$$

代入更新公式：

$$x_1 = x_0 - \eta f'(x_0) = 1 - 0.2(-4) = \boxed{1.8}.$$

更新前 $f(1) = 4$；更新后 $f(1.8) = 1.44$，确实下降了。继续照此计算：

迭代次数	当前 x	函数值 $f(x)$
0	1	4
1	1.8	1.44
2	2.28	0.5184
3	2.568	0.186624
4	2.7408	0.06718464

你可以看到 x 从 1 逐渐靠近 3，函数值越来越小。

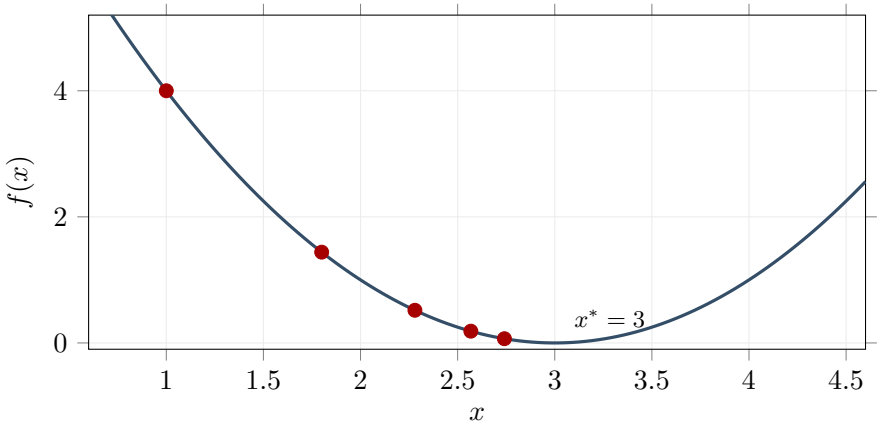


图 1: 从 $x_0 = 1$ 出发，学习率取 0.2 的几次梯度下降迭代。

3.4 从导数到梯度

刚才只有一个变量 x。线性回归有两个参数 w, b，损失函数是 $J(w, b)$。我们分别求偏导

$$\frac{\partial J}{\partial w}, \qquad \frac{\partial J}{\partial b}.$$

将两个偏导数按参数 (w, b) 的顺序排列，得到目标函数关于参数向量的**梯度**。其中 $\partial J/\partial w$ 表示固定 b 时 J 随 w 的变化率，$\partial J/\partial b$ 表示固定 w 时 J 随 b 的变化率，两者均在同一个参数点 (w, b) 处计算：

$$\boxed{\nabla J(w, b) = \begin{pmatrix} \partial J/\partial w \\ \partial J/\partial b \end{pmatrix}.} \tag{3.3}$$

因此，同时更新两个参数的规则是

$$\boxed{\begin{aligned} w_{\text{新}} &= w_{\text{旧}} - \eta \frac{\partial J}{\partial w}, \\ b_{\text{新}} &= b_{\text{旧}} - \eta \frac{\partial J}{\partial b}. \end{aligned}} \tag{3.4}$$

重要：两个偏导都在更新前的同一组旧参数上计算，然后一起更新。不要先改 w 再用新的 w 去计算这一步的 b。

3.5 线性回归的偏导数

对含截距的线性回归，取目标函数

$$J(w,b) = \frac{1}{2m}\sum_{i=1}^{m}(wx_i + b - y_i)^2.$$

利用复合函数求导法则：

$$\boxed{\begin{aligned} \frac{\partial J}{\partial w} &= \frac{1}{m}\sum_{i=1}^{m}(wx_i + b - y_i)x_i, \\ \frac{\partial J}{\partial b} &= \frac{1}{m}\sum_{i=1}^{m}(wx_i + b - y_i). \end{aligned}} \tag{3.5}$$

两式中的 $wx_i + b - y_i$ 均为第 i 个样本的预测值减真实值。由于 $\partial(wx_i + b - y_i)/\partial w = x_i$，对 w 求偏导时每一项还需乘以 x_i；由于 $\partial(wx_i + b - y_i)/\partial b = 1$，对 b 求偏导时不需要这一因子。最后对各样本的结果求平均。

3.6 双参数梯度下降

设训练数据为：

$$(x_1, y_1) = (0, 1), \qquad (x_2, y_2) = (1, 3).$$

线性模型 $\hat{y} = wx + b$ 的损失函数为

$$J(w,b) = \frac{1}{4}[(b-1)^2 + (w+b-3)^2]. \tag{3.6}$$

将两组数据分别代入模型：当 $x = 0$ 时，预测值为 b，预测误差为 $b - 1$；当 $x = 1$ 时，预测值为 $w + b$，预测误差为 $w + b - 3$。平方后求和，再除以 $2m = 4$，即可得到上式。

直接求导：

$$\frac{\partial J}{\partial w} = \frac{1}{2}(w + b - 3), \qquad \frac{\partial J}{\partial b} = \frac{1}{2}[(b-1) + (w+b-3)].$$

取初值 $w_0 = b_0 = 0$，学习率 $\eta = 0.2$。先在旧参数处计算：

$$\left.\frac{\partial J}{\partial w}\right|_{(0,0)} = -1.5, \qquad \left.\frac{\partial J}{\partial b}\right|_{(0,0)} = -2.$$

再一起更新：

$$\begin{aligned} w_1 &= 0 - 0.2(-1.5) = 0.3, \\ b_1 &= 0 - 0.2(-2) = 0.4. \end{aligned}$$

第一次更新后的模型便是

$$\boxed{\hat{y} = 0.3x + 0.4.} \tag{3.7}$$

检查一下：更新前 $J(0,0) = (1+9)/4 = 2.5$；更新后

$$J(0.3, 0.4) = \frac{(-0.6)^2 + (-2.3)^2}{4} = 1.4125.$$

这一次更新真的使损失下降了。继续计算偏导并更新，参数会逐渐接近 $w = 2, b = 1$，最终直线为 $\hat{y} = 2x + 1$。

3.7 学习率与收敛行为

学习率太小，每次只走一点，训练可能很慢。学习率太大，可能从最小值一侧跳到另一侧，甚至越走越远。**负梯度提供局部下降方向，并不保证使用任何学习率都能下降**。

还可以对刚才的一元二次函数做一个简单检查：

$$x_{k+1} - 3 = (1 - 2\eta)(x_k - 3).$$

所以固定学习率时，要让误差对任意初值逐渐趋于零，需要 $|1 - 2\eta| < 1$，即 $0 < \eta < 1$。**这只是对 $f(x) = (x-3)^2$ 的结论，不是所有函数的通用学习率范围**。

3.8 梯度下降的向量形式

当参数很多时，把它们记成向量 $\boldsymbol{\theta}$，就可以将所有偏导同时更新写作

$$\boxed{\boldsymbol{\theta}_{k+1} = \boldsymbol{\theta}_k - \eta_k \nabla J(\boldsymbol{\theta}_k).}$$

如果 J 是凸可微函数，一个梯度为零的点是全局极小点；但一般非凸函数并没有这样的保证。关于高维步长、曲率、收敛速度的更严格结论属于进阶优化理论，本课不把它们当作入门要求。

4 逻辑回归与二分类

4.1 从回归预测到分类概率

线性回归利用 $\hat{y} = wx + b$ 预测连续数值。若将任务改为预测学生是否通过考试，可使用二分类标签：

$$y = \begin{cases} 1, & \text{通过考试,} \\ 0, & \text{未通过考试.} \end{cases}$$

例如，考虑以下包含学习时间与是否通过考试的数据：

学习时间 x（小时）	是否通过 y
1	0
2	0
3	0
4	1
5	1

我们希望估计的是“通过的概率”。但直接把直线当作概率会出问题：假设线性预测为 $\hat{y} = 0.3x - 0.4$，则 $x = 1$ 时得到 -0.1，$x = 6$ 时得到 1.4。概率却必须在 0 到 1 之间。

因此，逻辑回归并不是直接把线性输出作为概率，而是**先计算线性得分，再用另一个函数把它映射到** $(0, 1)$。

4.2 Sigmoid 函数

定义 Logistic（常称 Sigmoid）函数：

$$\boxed{\sigma(z) = \frac{1}{1 + e^{-z}}, \qquad z \in \mathbb{R}.} \tag{4.1}$$

其中 e 为自然对数的底数。z 越大，输出越接近 1；z 越小，越接近 0；任何有限 z 的输出都严格在两者之间。

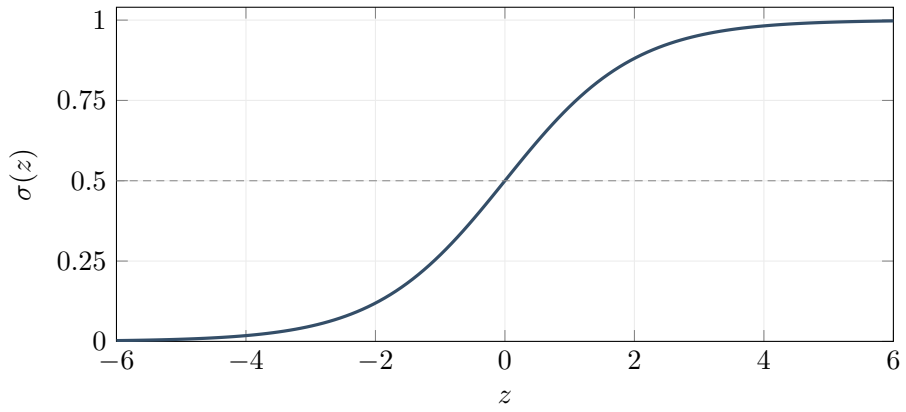


图 2: Sigmoid 函数：任意实数输入，输出一个介于 0 和 1 之间的数。

4.3 逻辑回归模型

设 $z = wx + b$，用 $\hat{p}$ 表示预测“通过”的概率：

$$\boxed{\hat{p} = P(Y = 1 \mid X = x) = \sigma(wx + b) = \frac{1}{1 + e^{-(wx+b)}}.} \tag{4.2}$$

例如 $w = 1, b = 0, x = 2$，则 $\hat{p} = \sigma(2) \approx 0.8808$，可解读为模型预测通过概率约 88.08%。是否最终输出类别 1，还需要指定阈值；常见做法是概率不小于 0.5 时预测类别 1。不过，**预测概率和最终分类结果并不是同一个概念**：0.88 表示模型估计正类概率约为 88%，而“类别 1”只是采用某个阈值后的决策。如果漏报的代价很高，实际任务可能选择更低的阈值；阈值的选取应结合模型评价与应用需求，而不是认为 0.5 永远最好。

4.4 对数几率的解释

将概率简记为 $p = \sigma(wx + b)$，那么

$$p = \frac{e^{wx+b}}{1 + e^{wx+b}}, \qquad 1 - p = \frac{1}{1 + e^{wx+b}}.$$

两式相除，再取自然对数：

$$\frac{p}{1-p} = e^{wx+b}, \qquad \boxed{\ln \frac{p}{1-p} = wx + b.}$$

这便是对数几率（log-odds）与线性特征的关系：

$$\log \frac{p}{1-p} = wx + b. \tag{4.3}$$

因此逻辑回归对**概率的对数几率**做线性建模，而不是要求概率本身随 x 线性变化[2]第 3 章。

4.5 伯努利模型与参数估计

设第 i 个样本的标签 $y_i \in \{0, 1\}$，模型给出的正类概率为 $p_i = \sigma(wx_i + b)$。因此

$$P(Y_i = 1 \mid x_i) = p_i, \qquad P(Y_i = 0 \mid x_i) = 1 - p_i.$$

两种情况可合并为伯努利分布的概率质量函数：

$$P(y_i \mid x_i) = p_i^{y_i}(1 - p_i)^{1-y_i}. \tag{4.4}$$

当 $y_i = 1$ 时，右边为 p_i；当 $y_i = 0$ 时，右边为 $1 - p_i$。

在给定特征后各样本类别条件独立的假设下，整批已观测标签的条件似然是

$$\mathcal{L}(w, b) = \prod_{i=1}^{m} p_i^{y_i}(1 - p_i)^{1-y_i}. \tag{4.5}$$

极大似然估计希望找到 w, b，使观测到这些标签的条件概率尽可能大。为方便求导，先取对数，把乘积变成求和：

$$\ln \mathcal{L}(w, b) = \sum_{i=1}^{m} \big[y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \big].$$

再乘负号并取平均，极大化便转化为熟悉的极小化：

$$\boxed{J(w, b) = -\frac{1}{m} \sum_{i=1}^{m} \left[y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \right].} \tag{4.6}$$

它叫作二**元交叉熵**（Binary Cross-Entropy，BCE），也是当前伯努利概率模型的平均负对数似然。

4.6 二元交叉熵的性质

单个样本的交叉熵是

$$\ell = -y \ln p - (1 - y) \ln(1 - p).$$

真实类别 y	预测正类概率 p	单样本损失 ℓ
1	0.9	0.105
1	0.1	2.303
0	0.1	0.105
0	0.9	2.303

如果真实类别是 1，预测概率 0.9 比 0.1 好得多；相反，如果真实类别是 0，预测 $p = 0.9$ 就意味着模型非常自信地预测错了，因此损失很大。这也是交叉熵相比只看“分类对不对”包含更多信息的原因。

4.7 交叉熵的梯度推导

利用梯度下降法估计参数，需要计算目标函数 J 对 w 和 b 的偏导数。首先求 Sigmoid 函数的导数：

$$\sigma'(z) = \frac{e^{-z}}{(1+e^{-z})^2} \tag{4.7}$$

$$= \boxed{\sigma(z)\big[1-\sigma(z)\big].} \tag{4.8}$$

第二步，对单样本交叉熵 $\ell = -y\ln p - (1-y)\ln(1-p)$ 关于 p 求导：

$$\frac{\partial \ell}{\partial p} = -\frac{y}{p} + \frac{1-y}{1-p}.$$

因为 $p = \sigma(z)$，链式法则给出

$$\begin{aligned}
\frac{\partial \ell}{\partial z} &= \frac{\partial \ell}{\partial p}\frac{\mathrm{d}p}{\mathrm{d}z} \\
&= \left(-\frac{y}{p} + \frac{1-y}{1-p}\right) p(1-p) \\
&= -y(1-p) + (1-y)p \\
&= \boxed{p-y}.
\end{aligned}$$

这一步最值得记住：**对线性得分 z 求导，得到预测概率减去真实标签**。

第三步，由 $z = wx + b$ 可知 $\partial z/\partial w = x$、$\partial z/\partial b = 1$。所以对所有样本取平均：

$$\boxed{\begin{aligned}
\frac{\partial J}{\partial w} &= \frac{1}{m}\sum_{i=1}^{m}(p_i - y_i)x_i, \\
\frac{\partial J}{\partial b} &= \frac{1}{m}\sum_{i=1}^{m}(p_i - y_i).
\end{aligned}} \tag{4.9}$$

对应的梯度下降更新为

$$\begin{aligned}
w_{\text{新}} &= w_{\text{旧}} - \eta\frac{1}{m}\sum_{i=1}^{m}(p_i - y_i)x_i, \\
b_{\text{新}} &= b_{\text{旧}} - \eta\frac{1}{m}\sum_{i=1}^{m}(p_i - y_i).
\end{aligned} \tag{4.10}$$

与线性回归很像：先算预测与真实值的差，再求平均并更新参数。只是逻辑回归用的是概率 p_i，线性回归用的是线性预测值 $\hat{y}_i$。

4.8 单次梯度更新

设一个样本 $x = 2, y = 1$，初始参数与学习率为

$$w_0 = 0, \quad b_0 = 0, \quad \eta = 0.1.$$

第一步，预测概率：

$$p_0 = \sigma(0 \times 2 + 0) = 0.5.$$

第二步，计算两个偏导：

$$\frac{\partial J}{\partial w} = (0.5 - 1) \times 2 = -1, \qquad \frac{\partial J}{\partial b} = 0.5 - 1 = -0.5.$$

第三步，更新：

$$w_1 = 0 - 0.1(-1) = 0.1, \qquad b_1 = 0 - 0.1(-0.5) = 0.05.$$

第四步，再预测：

$$p_1 = \sigma(0.1 \times 2 + 0.05) = \sigma(0.25) \approx 0.5622.$$

由于该样本标签为 1，模型预测的正类概率从 50% 上升到约 56.22%，这一步朝正确方向变化。单样本交叉熵也由约 0.6931 降到约 0.5759。**这只验证了当前样本的当前更新，并非任意学习率都保证下降**。

4.9 凸性与可分性

对于标准的线性逻辑回归，未正则化的平均负对数似然关于模型参数是凸函数；这不意味着 Sigmoid 曲线本身全局凸。凸性也不保证任意学习率都收敛，更不保证在每种数据集上都存在唯一的有限最优参数。例如数据线性完全可分时，未加正则化的参数极大似然估计可能没有有限解。这些是进一步学习优化理论时需要考虑的边界，本课只需知道它们存在。

5 过拟合、泛化与模型评价

5.1 泛化问题的直观例子

考虑三组学习时间与成绩的数据：

学生	每天学习时间	成绩
A	1 小时	60
B	2 小时	70
C	3 小时	80

有两个模型都能把这三组训练数据预测正确。

模型 A：根据线性规律预测，$f_A(x) = 50 + 10x$。

模型 B：把“1 小时对应 60、2 小时对应 70、3 小时对应 80”直接记住；遇到其他学习时间统一预测 60。

两者在训练集上的 MSE 都为 0。现在来了没有参加训练的学生 D，学习时间 4 小时，假设真实成绩是 90。模型 A 预测 90，平方损失为 0；模型 B 预测 60，平方损失为 $(90-60)^2 = 900$。

比较项目	模型 A	模型 B
训练集 MSE	0	0
新样本预测	90	60
新样本平方损失	0	900

所以，**训练误差一样小，不代表新数据上的效果一样好**。

5.2 过拟合与欠拟合

过拟合（Overfitting）指模型过度适应训练样本的细节，甚至记住其中的噪声和偶然性，结果在未见数据上表现不佳。刚才的记忆模型就是直观示例。

欠拟合（Underfitting）则是模型能力或训练程度不足，没能充分表示数据中的主要规律。例如数据明显呈曲线趋势，却始终只用一条直线拟合，训练误差可能很大，新数据预测也不理想。

情况	训练数据表现	未见数据表现
欠拟合	常常不好	常常不好
合理拟合	能学到主要规律	相对稳定
过拟合	可能特别好	可能明显变差

模型更复杂并非一定过拟合，模型更简单也并非一定欠拟合。关键是看它是否适应真实数据规律，以及是否能推广到新数据。

5.3 训练、测试与泛化误差

训练误差在用来训练模型的样本上计算。以平方损失为例：

$$\mathrm{MSE}_{\text{train}} = \frac{1}{m}\sum_{i=1}^{m}(y_i - \hat{f}(x_i))^2. \tag{5.1}$$

测试误差在未参与训练的数据上计算。如果测试集有 n 个样本，就写为

$$\mathrm{MSE}_{\text{test}} = \frac{1}{n}\sum_{i=1}^{n}(y_i' - \hat{f}(x_i'))^2.$$

泛化误差关心模型对目标数据分布中的新观测的平均损失。假设训练得到的 $\hat{f}$ 已经确定，定义

$$R(\hat{f}) = \mathbb{E}_{(X,Y)\sim P}[L(Y, \hat{f}(X))]. \tag{5.2}$$

$\mathbb{E}$ 是期望，P 是目标数据的联合分布。我们通常不知道这个分布，所以难以直接计算 $R(\hat{f})$；独立测试集上的平均损失只是它的**统计估计**。

5.4 训练集、验证集与测试集

训练集用于确定模型参数，例如线性回归中的 w, b。**验证集**用于比较模型或选择超参数，例如选择多项式次数、学习率。**测试集**在模型选择完成后用于最终评估，尽量不要反复用于调参。

假设有 10 000 条样本，一种示例划分是训练集 7 000 条、验证集 1 500 条、测试集 1 500 条（70%/15%/15%）。这不是固定标准：样本量、时间顺序、是否有重复测量等都会影响合理划分。

为什么不能在测试集上反复挑选模型？因为它虽然没有参与梯度计算，却已经参与了模型选择，最后的测试成绩可能因此偏于乐观。测试集最重要的价值是**保持独立**。例如，一个学生的多次测试记录如果同时出现在训练集和测试集，模型可能借助学生特有的信息“认出”测试样本，导致评估偏高。这类数据往往更适合按学生分组划分，而不是把每条记录独立随机拆分。具体划分方法要服从数据的产生方式。

5.5 留出法与 K 折交叉验证

留出法（Hold-out）是把数据拆成相互不重叠的训练部分与评价部分，例如 700 条训练、300 条测试。不同随机划分可能带来不同结果。

K 折交叉验证（K-Fold Cross Validation）利用多次划分缓解偶然性。以 5 折为例：

1. 将训练部分划分为五份，记作第 1 ~ 5 折。
2. 第一次用第 2 ~ 5 折训练，用第 1 折验证。
3. 第二次用第 1、3、4、5 折训练，用第 2 折验证。
4. 依次轮换，使每一折都恰好作为一次验证集。
5. 把五次验证误差汇总，用来比较模型。

当各折样本量相同时，交叉验证平均误差为

$$\boxed{E_{\mathrm{CV}} = \frac{1}{K}\sum_{k=1}^{K} E_k.} \tag{5.3}$$

E_k 表示第 k 次验证的平均误差。若各折样本数 n_k 不同，若希望求所有折外预测的样本平均，则使用加权式

$$E_{\mathrm{CV,weighted}} = \frac{\sum_k n_k E_k}{\sum_k n_k}. \tag{5.4}$$

五折、十折都是常见的交叉验证方案；折数的选择需要结合样本量与估计精度。

5.6 数据泄漏

假设准备把特征标准化：

$$z = \frac{x-\mu}{\sigma}.$$

若先用全部数据计算均值 μ 和标准差 σ，然后才划分训练与测试，那么测试集的信息已经提前进入训练流程，这叫作**数据泄漏**（Data Leakage）。

正确的基本步骤是：只在训练数据上学习预处理参数，再用这些参数转换验证集和测试集。交叉验证时也必须在每一折的训练部分重新拟合标准化器。数据泄漏可能让评价结果看起来比实际部署效果更好。

5.7 偏差与方差

为什么增加模型复杂度通常能降低训练误差，却不一定改善测试效果？一个常用的分析视角是**偏差—方差权衡**。

偏差（Bias）描述模型的平均预测相对于真实规律的系统性偏离。例如真实规律是一条弯曲的曲线，却坚持用直线去拟合，就可能存在较大偏差。

方差（Variance）描述模型对训练数据变化的敏感程度。换一批训练样本，模型预测就发生很大变化，通常意味着较高的方差。

不可约误差则来自观测中的随机噪声，即使知道真实规律也未必能把每个样本预测到完全准确。

在适当条件下，例如固定输入 x、$Y = f(x) + \varepsilon$、噪声均值为零、方差为 σ^2 且与训练过程独立，平方预测误差可以分解为

$$\mathbb{E}[(Y - \hat{f}_D(x))^2] = \mathrm{Bias}(\hat{f}_D(x))^2 + \mathrm{Var}(\hat{f}_D(x)) + \sigma^2. \tag{5.5}$$

这里的期望要同时对重复抽取的训练数据与新的观测噪声考虑。

5.8 回归模型评价指标

回归任务常用的评价指标是均方误差（MSE）：

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2.$$

例如真实值为 $(10, 20, 30)$，预测为 $(11, 18, 33)$，平方误差就是 $1, 4, 9$，所以 $\mathrm{MSE} = (1+4+9)/3 = 14/3$。比较模型时，必须说明是在训练集、验证集还是测试集上算的 MSE。

5.9 分类指标与混淆矩阵

分类模型可以使用**准确率**（Accuracy）：

$$\mathrm{Accuracy} = \frac{\text{预测正确的样本数}}{\text{总样本数}}.$$

但准确率不总够用。假设 100 个样本只有 5 个正类，全部预测为负类也有 95% 准确率，却一个正类也没有找出。

二分类中常用四个缩写：

- TP：实际为正，预测也为正（真正例）；
- FP：实际为负，误报为正（假正例）；
- TN：实际为负，预测也为负（真反例）；
- FN：实际为正，漏报为负（假反例）。

表 2: 二分类混淆矩阵

	预测正类	预测负类
实际正类	$TP = 24$	$FN = 16$
实际负类	$FP = 6$	$TN = 54$

查准率（Precision）是所有预测为正的样本中真实正类所占比例：

$$\mathrm{Precision} = \frac{TP}{TP + FP} = \frac{24}{24 + 6} = 80\%.$$

查全率（Recall）是所有实际正类样本中被正确预测为正类的比例：

$$\mathrm{Recall} = \frac{TP}{TP + FN} = \frac{24}{24 + 16} = 60\%.$$

如果希望同时考虑两者，常用它们的调和平均 F_1：

$$\boxed{F_1 = \frac{2PR}{P + R} = \frac{2 \times 0.8 \times 0.6}{0.8 + 0.6} \approx 0.686.}$$

在 F_1 的计算中，P 表示查准率（Precision），R 表示查全率（Recall）。调和平均可以综合衡量查准率与查全率：当其中一项明显较低时，F_1 也会受到影响。上述指标的分母为零时须明确处理规则。

分类阈值变化时，查准率与查全率可能随之改变。ROC 曲线以假正例率 $\mathrm{FPR} = FP/(FP + TN)$ 为横轴、真正例率 $\mathrm{TPR} = TP/(TP + FN)$ 为纵轴，展示不同分类阈值下的表现。ROC 曲线下面积称为 AUC，反映模型区分正负样本的排序能力；它与固定阈值下的准确率评价角度不同。

5.10 多项式回归

考虑数据生成关系 $y = \sin x + \varepsilon$，其中 ε 为均值为零的随机扰动。针对一组固定的数据划分，记录不同次数多项式拟合得到的训练与测试 MSE：

表 3: 不同多项式次数对应的训练与测试误差

多项式次数	训练 MSE	测试 MSE	观察
1	0.1869	0.1740	模型较简单，误差偏高
8	0.0368	0.0359	本次训练和测试误差均较低
25	0.0269	0.2600	训练更好，测试明显变差

A 常用数学符号

符号	本笔记中的含义
x_i	第 i 个样本的输入（单个特征时为一个数）。
$\boldsymbol{x}_i$	第 i 个样本的多个数值特征组成的向量。
y_i	第 i 个样本的真实结果或标记。
$\hat{y}_i$	模型对第 i 个样本的预测结果。
m, n	样本数量；不同课中可能使用不同字母。
d, p	特征维数或参数维数，具体按公式附近的定义使用。
D	训练数据集。
w, b	一元线性或逻辑回归的斜率（权重）、截距（偏置）。
$\bar{x}, \bar{y}$	输入和目标的样本均值。
e_i	残差；不同章节需留意预测减真实、或真实减预测的约定。
L	单个样本的损失函数。
RSS	残差平方和。
MSE	均方误差，平方误差的样本平均。
J	训练时要减小的目标函数；有时为 MSE 的一半。
$\mathcal{F}$	候选模型构成的集合（模型族）。
$\widehat{R}_D(f)$	模型在训练样本上的平均损失（经验风险）。
$R(f)$	在目标数据分布下的期望损失（总体风险）。
η	梯度下降的学习率。
∇J	把各参数的偏导数组合成的梯度向量。
$\sigma(z)$	Sigmoid 函数，$\sigma(z) = 1/(1 + e^{-z})$。
p_i	逻辑回归对第 i 个样本预测的正类概率。
TP, FP, TN, FN	真正例、假正例、真反例、假反例。
K	K 折交叉验证的折数。
$\mathbb{E}$	数学期望，即按概率分布取平均。

$\{w \in \mathbb{R} \mid w > 0\}$。

B 修订记录

日期	版本	主要变更
2026-11-12	v0.5	根据批注删除冗余章节与复习性段落，补充 RSS、偏导数及梯度的说明，并修订相关表述。
2026-11-11	v0.4	精简目录，统一章节及小节标题。
2026-11-11	v0.3	整理机器学习基础内容，完善公式推导和数值算例。
2026-11	v0.1	建立 LaTeX 文稿与参考文献结构。

参考文献

[1] 李航. 统计学习方法[M]. 2 版. 清华大学出版社, 2019.

[2] 周志华. 机器学习[M]. 清华大学出版社, 2016.